

UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

FACULTAD DE CIENCIAS



ALMACENES Y MINERÍA DE DATOS

PROYECTO FINAL - ANÁLISIS DE INCIDENCIA DELICTIVA EN MÉXICO
2015-2025

Alumnos:

- Méndez Ávila Luis Geovanni 317143980
- Paredes Zamudio Luis Daniel 318159926
- Sánchez Rosas Roberto Samuel 318355159

Profesora: L. en C.C. Jessica Santizo Galicia

10 de Junio de 2026

Índice

1. Introducción: Análisis de la Incidencia Delictiva Estatal	2
2. Análisis Exploratorio de Datos	2
2.1. Diccionario de Datos	2
2.2. Overview del Dataset	3
2.3. Calidad y Limpieza de los Datos	4
2.4. Estadísticas Descriptivas Numéricas	5
2.4.1. Histogramas de incidencia delictiva	5
2.5. Estadísticas Descriptivas Categóricas	8
2.5.1. Delitos más Comunes	8
2.5.2. Incidencia Delictiva por Estado	9
2.5.3. Bienes Jurídicos más Afectados	12
2.5.4. Modalidad de los Delitos	13
2.5.5. Delincuencia por Año	14
2.6. Detección de Outliers	17
3. Modelos	18
3.1. Carga y preparación de datos	19
3.2. Preprocesamiento y división train/test	20
3.3. Entrenamiento del modelo	21
3.4. Evaluación del modelo	22
3.4.1. Importancia de features	23
3.5. Interpretación del Modelo	24
3.5.1. Análisis gráfico	25
3.6. Comparación con Línea Base	26
3.7. Persistencia del modelo	27
3.8. Conclusiones sobre el modelo	27
3.8.1. Limitaciones	28
4. Clustering y Análisis de Componentes Principales	28
4.1. ¿Por qué se decidió usar K-Means?	28
4.2. Preparación de los Datos y Construcción de la Matriz de Proporciones	29
4.3. Consideración sobre la Dimensionalidad y Visualización	30
4.4. Selección del Número Óptimo de Clusters	30
4.5. Resultados de la Matriz de Proporciones y Perfil de Clusters	33
4.6. Interpretación de los Clusters	33
4.6.1. #0 – Perfil de Violencia contra las Personas	33
4.6.2. #1 – Perfil Diversificado de Otros Bienes Jurídicos	34
4.6.3. #2 – Perfil Familiar y de Libertad Personal	34
4.6.4. #3 – Perfil Patrimonial	34
4.7. Tabla de Segmentación	34
4.8. Proyección PCA	34
4.9. Perfiles bajo la Proyección PCA	37
4.9.1. #1 - Perfil Diversificado	37
4.9.2. #0 y #2 - Perfiles de Violencia y Entorno Familiar	37
4.9.3. #3 - Perfil Patrimonial	38
5. Conclusiones	38

1. Introducción: Análisis de la Incidencia Delictiva Estatal

No es noticia nueva de que México sufre de un serio problema de delincuencia. Y esto, desgraciadamente, no ha disminuido considerablemente en 10 años a la fecha. Pero la realidad es que distintos estados de la república sufren de delitos en particular que, aunque presentes en otros lugares, no son el principal foco del lugar.

Nuestro objetivo al analizar la incidencia delictiva es poder identificar no solo cuáles son éstos delitos los más preliminares en cada estado, si no también poder crear un modelo que establezca cual es delito más probable que pueda sufrir un ciudadano de un estado en particular.

Desgraciadamente, todos somos propensos a sufrirlos, pero identificarlos no solo nos permite a nosotros como habitantes poder prepararnos para evitarlos lo más que se pueda, como le puede servir a las autoridades componentes para concientizar y, utópicamente, idear soluciones que reduzcan verdaderamente la epidemia de delincuencia que sufre el país.

Este dataset pertenece a la [Plataforma Nacional de Datos Abiertos Mexicana](#) y fue creado por el Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública (SESNSP). Este dataset, nombrado simplemente como *Incidencia Delictiva*, puede descargarse siguiendo [este enlace](#).

2. Análisis Exploratorio de Datos

Haremos un análisis exploratorio para conocer el dataset en profundidad y poder identificar patrones, tendencias y relaciones entre las variables. Esto nos permitirá tomar decisiones informadas sobre cómo abordar el problema de la incidencia delictiva más adelante en el proyecto, principalmente para crear el modelo de predicción adecuado a este problema.

Para esto, haremos limpieza, análisis estadístico, detección de outliers y visualización de los datos.

Como mencionamos en la sección anterior, cada sección de este análisis se irá documentando con código y resultados, para poder seguir el proceso de manera clara y transparente. De igual manera, el cuaderno de Jupyter con el código completo de este análisis se encuentra disponible [aquí](#), mientras que el código fuente de ésta sección se encuentra disponible en [ésta carpeta](#) del repositorio del proyecto.

2.1. Diccionario de Datos

```
1 import sys
2 from pathlib import Path
3
4 # Resuelve el problema de las ubicaciones de los scripts
5 sys.path.insert(0, str(Path.cwd().parent))
6
7 import pandas as pd
```

```

8 import matplotlib.pyplot as plt
9 import seaborn as sns
10
11 from src import config
12 from src.data import DataRepository
13 from src.preprocessing import PreprocessingPipeline
14 from src.eda import StatisticsAnalyzer, OutlierDetector
15
16 # Tema visual por defecto del proyecto.
17 sns.set_theme(style=config.SEABORN_THEME, palette=config.PLOT_PALETTE)
18 pd.set_option("display.max_columns", 20)
19 pd.set_option("display.width", 140)
20 pd.set_option("display.max_colwidth", 200)
21
22 repo = DataRepository()
23 dataframe = repo.load()
24 repo.dictionary()

```

Listing 1: Código para generar el diccionario de datos

Tabla 1: Diccionario de datos

Índice	Nombre (tipo)	Descripción
0	anio (int64)	Año de registro de las averiguaciones previas y/o carpetas de investigación.
1	clave_ent (int64)	Clave de la entidad, según el Marco Geoestadístico Nacional (MGN) del Instituto Nacional de Geografía y Estadística (INEGI).
2	entidad (str)	Entidad federativa de registro de las averiguaciones previas y/o carpetas de investigación.
3	bien_juridico_afectado (str)	Primera clasificación de los delitos en las averiguaciones previas y/o carpetas de investigación. (Patrimonio, vida, libertad, etc.)
4	tipo_delito (str)	Segunda clasificación de los delitos. (Falsedad, Lesiones, Robo, etc.)
5	subtipo_delito (str)	Tercera clasificación de los delitos. Subcategorías específicas de cada tipo de delito. (Lesiones dolosas, etc.).
6	modalidad (str)	Cuarta clasificación de los delitos. Forma en la que se comete el delito. (Con violencia, sin violencia, etc.)
7	mes (str)	Mes de registro de las averiguaciones previas y/o carpetas de investigación.
8	fecha (str)	Fecha de registro de las averiguaciones previas y/o carpetas de investigación.
9	incidencia_delictiva (int64)	Incidencia delictiva del Fuero Común (Número absoluto de presuntos delitos registrados).
10	entidad_federativa (str)	Entidad federativa de registro de las averiguaciones previas y/o carpetas de investigación.

2.2. Overview del Dataset

```

1 dataframe

```

Listing 2: Código para obtener un overview del dataset

El dataset contiene 413,952 registros que abarcan desde enero de 2015 hasta diciembre de 2025 (11 años). Los datos están organizados a nivel estatal con granularidad mensual (32 entidades $\times$ 40+ tipos de delito $\times$ 132 meses), lo que nos permite hacer análisis longitudinales de la evolución del delito en cada estado.

Tabla 2: Muestra del dataset: primeras filas

idx	año	clave_ent	entidad	bien_juridico.afectado	tipo_delito	subtipo_delito	modalidad	mes	fecha	incidencia_delictiva	entidad_federativa
0	2015	1	Aguascalientes	El patrimonio	Abuso de confianza	Abuso de confianza	Abuso de confianza	Abril	2015-04-01	22	Aguascalientes
1	2015	1	Aguascalientes	El patrimonio	Abuso de confianza	Abuso de confianza	Abuso de confianza	Agosto	2015-08-01	40	Aguascalientes
2	2015	1	Aguascalientes	El patrimonio	Abuso de confianza	Abuso de confianza	Abuso de confianza	Diciembre	2015-12-01	26	Aguascalientes
3	2015	1	Aguascalientes	El patrimonio	Abuso de confianza	Abuso de confianza	Abuso de confianza	Enero	2015-01-01	41	Aguascalientes
4	2015	1	Aguascalientes	El patrimonio	Abuso de confianza	Abuso de confianza	Abuso de confianza	Febrero	2015-02-01	33	Aguascalientes

Tabla 3: Muestra del dataset: últimas filas

idx	año	clave_ent	entidad	bien_juridico.afectado	tipo_delito	subtipo_delito	modalidad	mes	fecha	incidencia_delictiva	entidad_federativa
413947	2025	32	Zacatecas	Otros bienes jurídicos afectados (del fuero común)	Otros delitos del Fuero Común	Otros delitos del Fuero Común	Otros delitos del Fuero Común	del Marzo	2025-03-01	184	Zacatecas
413948	2025	32	Zacatecas	Otros bienes jurídicos afectados (del fuero común)	Otros delitos del Fuero Común	Otros delitos del Fuero Común	Otros delitos del Fuero Común	del Mayo	2025-05-01	98	Zacatecas
413949	2025	32	Zacatecas	Otros bienes jurídicos afectados (del fuero común)	Otros delitos del Fuero Común	Otros delitos del Fuero Común	Otros delitos del Fuero Común	del Noviembre	2025-11-01	92	Zacatecas
413950	2025	32	Zacatecas	Otros bienes jurídicos afectados (del fuero común)	Otros delitos del Fuero Común	Otros delitos del Fuero Común	Otros delitos del Fuero Común	del Octubre	2025-10-01	99	Zacatecas
413951	2025	32	Zacatecas	Otros bienes jurídicos afectados (del fuero común)	Otros delitos del Fuero Común	Otros delitos del Fuero Común	Otros delitos del Fuero Común	del Septiembre	2025-09-01	133	Zacatecas

2.3. Calidad y Limpieza de los Datos

Haremos lo siguiente con el dataset original:

- Borramos las columnas `año` y `mes` para poder trabajar únicamente con `fecha`. Posteriormente, ésta última pasará a ser de tipo `datetime`.
- `entidad_federativa` es un duplicado de `entidad`, por lo que borramos ésta columna.
- `clave_entidad` no nos es de utilidad al ya tener el nombre de las entidades, por lo que borramos ésta columna.
- Analizamos el dataset en busca de duplicados y valores nulos.
- Consideraremos que una entrada es inválida si tiene valores NaN en `incidencia_delictiva`, `fecha` y `entidad`. Una vez detectadas, serán eliminadas.
- Por revisión manual, vemos que algunos estados tienen su nombre completo, como `Veracruz de Ignacio de la Llave`. Acortaremos el nombre de estos estados para una visualización más limpia de la información.

```

1 cleaning_pipeline = PreprocessingPipeline(
2     drop_columns=["año", "clave_ent", "mes", "entidad_federativa"]
3 )
4 clean_dataset = cleaning_pipeline.run(dataframe)
5 # reorganizamos las columnas para tener la fecha como columna inicial del dataset
6 clean_dataset = clean_dataset.iloc[:, [5, 0, 1, 2, 3, 4, 6]]
7 cleaning_pipeline.save(clean_dataset)

```

Listing 3: Código para limpiar el dataset

```

1 [1] Eliminando columnas declaradas en drop_columns
2     Eliminadas: ['año', 'clave_ent', 'mes', 'entidad_federativa']
3 [2] Convirtiendo '{self._date_col}' a datetime
4     OK=413,952 / fallidos=0

```

```

5  Rango: 2015-01-01 - 2025-12-01
6  [3] Eliminando filas con nulos en críticas
7  Filas: 413,952 - 413,952 (eliminadas: 0)
8  [4] Eliminando duplicados exactos
9  Filas: 413,952 - 413,952 (eliminadas: 0)
10 [5] Normalizando nombres de entidades federativas
11 413,952 filas x 7 columnas,

```

Vemos que, a pesar de ser un dataset de origen gubernamental, éste no contiene duplicados ni entradas inválidas. Por lo que solo se realizó la conversión de fechas y la eliminación de las columnas con las que no trabajaremos.

2.4. Estadísticas Descriptivas Numéricas

En base a la naturaleza de nuestro dataset, el análisis estadístico se centrará principalmente en la variable `incidencia_delictiva`, que representa el número de delitos reportados para cada combinación de estado, tipo de delito y fecha.

Veamos algunas estadísticas descriptivas clave para esta variable:

```

1 # Carga del dataset limpio para análisis estadístico
2 repo = DataRepository("../data/processed/INM_estatal_dic25_clean.csv")
3 dataframe = repo.load()
4 stats = StatisticsAnalyzer(dataframe)
5 stats.numeric_stats()

```

Listing 4: Código para obtener estadísticas descriptivas numéricas

Tabla 4: Estadísticas Descriptivas Numéricas

idx	columna	Promedio	Mediana	Desviación Estándar	Valor Mínimo	Q1	Q3	Valor Máximo	Rango
0	incidencia_delictiva	52.499106	2.0	204.518424	0.0	0.0	26.0	9968.0	9968.0

La media (52.5) es muy superior a la mediana (2.0), lo que indica un sesgo severo hacia la derecha. La mayoría de los registros tienen baja incidencia (2 delitos), pero algunos delitos registran valores enormes (siendo 9,968 el valor máximo). Sin embargo, en un contexto real, la CDMX y el EdoMex son probablemente las entidades con valores más altos y más concentrados debido a su población y urbanización. Validaremos esto más adelante.

En ese sentido, esto no sería (necesariamente) un sesgo en los datos, si no que refleja disparidades geográficas genuinas en la delincuencia. Sin embargo, eso no significa que, nuevamente en un contexto real, no se reporte de la misma manera en otros estados.

2.4.1. Histogramas de incidencia delictiva

```
1 fig, axes = plt.subplots(2, 1, figsize=(10, 12))
2
3 sns.histplot(
4     data=dataframe,
5     x="incidencia_delictiva",
6     bins=50,
7     color="crimson",
8     ax=axes[0]
9 )
10 axes[0].set_title("A) Histograma en Escala Original\n(Sesgo Extremo hacia la Derecha)",
11                  fontsize=12, fontweight="bold")
12 axes[0].set_xlabel("Número de Delitos por Registro")
13 axes[0].set_ylabel("Frecuencia (Cantidad de Registros)")
14 axes[0].grid(True, linestyle="--", alpha=0.5)
15
16 df_non_zero = dataframe[dataframe["incidencia_delictiva"] > 0]
17 sns.histplot(
18     data=df_non_zero,
19     x="incidencia_delictiva",
20     kde=True,
21     log_scale=True,
22     color="darkblue",
23     ax=axes[1]
24 )
25 axes[1].set_title("B) Histograma en Escala Logarítmica\n(Estructura Interna de la Incidencia
26                    )", fontsize=12, fontweight="bold")
27 axes[1].set_xlabel("Número de Delitos por Registro (Escala Logarítmica)")
28 axes[1].set_ylabel("Frecuencia (Cantidad de Registros)")
29 axes[1].grid(True, linestyle="--", alpha=0.5)
30
31 plt.suptitle("Análisis de Distribución de la Incidencia Delictiva en México", fontsize=15,
32              fontweight="bold", y=1.02)
33 plt.tight_layout()
34 plt.show()
```

Listing 5: Código para generar histogramas de incidencia delictiva

Análisis de Distribución de la Incidencia Delictiva en México




Figura 1: Histogramas de Incidencia Delictiva por Estado (marcador de posición)

El primer gráfico muestra una distribución con un sesgo hacia la derecha extremadamente severa. La inmensa mayoría de los registros del dataset se concentran de forma masiva en valores muy cercanos a cero (recordemos que la mediana del dataset es de 2 delitos por registro). Esto se debe a que existen muchas categorías de delitos poco comunes o entidades con menor población que reportan frecuentemente cero u muy pocas incidencias mensuales de estos delitos no tan comunes. Visualmente, esto genera una gran "pared" en el extremo izquierdo y una cola invisible infinitamente larga hacia la derecha que se extiende hasta el valor máximo de 9,968.

Con el segundo gráfico queremos revelar la distribución real que queda oculta bajo el sesgo. Para esto se aplicó una escala logarítmica sobre el eje de las abscisas (filtrando los registros con delitos). Esto nos da

distribución con dos picos:

- El primero muestra cuando se registran de 1 a 3 delitos en promedio. Esto representa la gran masa de reportes delictivos de baja ocurrencia o zonas con baja densidad demográfica.
- El segundo muestra cuando se registran de 30 a 100 delitos en promedio. Esto representa la acumulación de delitos altamente recurrentes (como variantes de robos) en zonas urbanas o de alta incidencia.

2.5. Estadísticas Descriptivas Categóricas

```
1 stats.categorical_stats()
```

Listing 6: Código para obtener estadísticas descriptivas categóricas

Tabla 5: Estadísticas Descriptivas Categóricas

idx	columna	valores únicos	moda	frecuencia modal
0	fecha	132	2015-04-01	3136
1	entidad	32	Aguascalientes	12936
2	bien_juridico_afectado	7	El patrimonio	177408
3	tipo_delito	40	Robo	152064
4	subtipo_delito	55	Robo de maquinaria	25344
5	modalidad	59	Con violencia	50688

En cuanto a las variables categóricas del conjunto de datos podemos notar hechos bastante interesantes a pesar de la inmensidad del dataset:

- El dataset es de 11 años, sin embargo, solo hay 132 fechas únicas, con la fecha inicial siendo el 01 de enero de 2015
- La moda del dataset tiene algunos resultados curiosos. Este conjunto de datos es simétrico para cada estado, ya que existen 12936 líneas para c/u. Entonces, al querer calcular la moda se toma el valor inicial de manera alfabética y resulta ser Aguascalientes. Sin embargo, esto no significa que sea la entidad con mayor apariciones del dataset.
- Lo anterior pasa de igual manera con la fecha, ya que toma la primera fecha del dataset para calcular este valor.
- El dataset reporta 40 tipos de delitos únicos reportados, con Robo siendo la categoría principal.

Veamos ahora un análisis más detallado de las variables categóricas.

2.5.1. Delitos más Comunes

```
1 crime_counts = dataframe["tipo_delito"].value_counts().head(10)
2
3 fig, ax = plt.subplots(figsize=(10, 4))
```

```

4 crime_counts.plot(kind="barh", ax=ax, color="steelblue")
5 ax.set_title("Top 10 Tipos de Delito", fontsize=13, fontweight="bold")
6 ax.set_xlabel("Número de Registros")
7 ax.invert_yaxis()
8
9 # Añade valores en las barras
10 for i, v in enumerate(crime_counts.values):
11     ax.text(v + 1000, i, f"{v:,}", va="center", fontsize=10)
12
13 plt.tight_layout()
14 plt.show()

```

Listing 7: Código para generar gráfico de los delitos más comunes




Figura 2: Top 10 Tipos de Delito

Como se mencionaba en la tabla anterior, robo es el delito más reportado, seguido de homicidio y lesiones. Algo a recordar es que aunque los feminicidios son también homicidios éstos están en una categoría separada debido al motivo por el que ocurren. Vemos también que hay una extraña coincidencia de valores entre Abuso de Confianza, Daño a la Propiedad, Despojo, Extorsión y Fraude, lo que sugiere un sesgo al momento de reportar estos delitos por parte de la autoridad (por ejemplo, cifras redondeadas, reportes nulos, etc.)

2.5.2. Incidencia Delictiva por Estado

```

1 from matplotlib.ticker import StrMethodFormatter
2
3 entidad_counts = (
4     dataframe.groupby("entidad")["incidencia_delictiva"]
5     .sum()
6     .sort_values(ascending=False)
7     .head(10)
8 )
9

```

```

10 fig, ax = plt.subplots(figsize=(10, 6))
11 bars = ax.bar(entidad_counts.index, entidad_counts.values, color="coral")
12 # Formato del eje Y con separadores de miles y sin decimales
13 ax.yaxis.set_major_formatter(StrMethodFormatter("{x:,.0f}"))
14 # Agregamos los valores reales arriba de cada barra con separadores de miles
15 ax.bar_label(bars, fmt="{:,.0f}", padding=3, fontsize=10, fontweight="bold")
16
17 ax.set_title(
18     "Incidencia Delictiva Total por Entidad (Top 10) - 2015 a 2025",
19     fontsize=15,
20     fontweight="bold",
21     pad=15,
22 )
23 ax.set_ylabel("Total de Delitos", fontsize=12)
24 ax.set_xlabel("Entidad Federativa", fontsize=12)
25 ax.tick_params(axis="x", rotation=40)
26
27 plt.tight_layout()
28 plt.show()

```

Listing 8: Código para generar gráfico de incidencia delictiva por estado




Figura 3: Incidencia Delictiva Total por Entidad

Nuestra sospecha anterior que la EdoMex y la CDMX son los estados con más reportes es correcta. Vemos que le siguen Jalisco, Guanajuato y Baja California y que, a pesar de la moda, Aguascalientes no figura dentro de los estados con más delitos reportados.

```

1 top_crimes = dataframe["tipo_delito"].value_counts().head(10).index

```

```
2 top_entities = dataframe["entidad"].value_counts().head(10).index
3
4 filtered_df = dataframe[dataframe["tipo_delito"].isin(top_crimes) & dataframe["entidad"].
    isin(top_entities)]
5
6 pivot = filtered_df.pivot_table(
7     values="incidencia_delictiva", index="entidad", columns="tipo_delito", aggfunc="sum"
8 )
9
10 fig, ax = plt.subplots(figsize=(10, 10))
11 sns.heatmap(
12     pivot,
13     cmap="RdYlGn_r",
14     annot=True,
15     fmt=",.0f", # Agregamos la coma para que los números dentro del mapa tengan comas (ej.
16     1,234,567)
17     cbar_kws={"label": "Incidencia"},
18     ax=ax,
19 )
20 cbar = ax.collections[0].colorbar
21 # aplicamos formato con comas de miles y sin decimales
22 cbar.ax.yaxis.set_major_formatter(StrMethodFormatter('{x:,.0f}'))
23
24 ax.set_title(
25     "Incidencia por Entidad y Tipo de Delito",
26     fontsize=12,
27     fontweight="bold",
28     pad=15
29 )
30
31 plt.tight_layout()
32 plt.show()
```

Listing 9: Código para generar mapa de calor de incidencia por entidad y tipo de delito




Figura 4: Mapa de calor de incidencia por entidad y tipo de delito

2.5.3. Bienes Jurídicos más Afectados

```

1 bien_juridico = dataframe["bien_juridico_afectado"].value_counts()
2
3 fig, ax = plt.subplots(figsize=(8, 8))
4 wedges, texts, autotexts = ax.pie(
5     bien_juridico.values, labels=bien_juridico.index, autopct="%1.1f%%", startangle=90
6 )
7 ax.set_title(
8     "Distribución de Delitos por Bien Jurídico Afectado", fontsize=11, fontweight="bold"
9 )
10 for autotext in autotexts:
11     autotext.set_color("white")
12
13 plt.show()

```

Listing 10: Código para generar gráfico de bienes jurídicos más afectados




Figura 5: Bienes Jurídicos más Afectados por Delitos en México (2015-2025)

Para entender esta gráfica debemos entender que la ley define como ‘bienes jurídicos’ a aquellos objetos o relaciones, tangibles o intangibles, que cuentan con la protección de la ley, como un inmueble, la vida, dinero, etc. En particular, debemos entender que ‘El patrimonio’ hace referencia al conjunto de bienes, derechos y obligaciones de una persona, susceptibles de valoración económica. Lo anterior, en otros términos, se refiere a pertenencias que hemos comprado, dinero que tenga un individuo, etc, pero que tengan relevancia económica.

Ahora pues, tomando en cuenta de que el delito más reportado es el robo, que el patrimonio sea el bien más afectado tiene mucho sentido. Luego, al ser el homicidio, lesiones, secuestro y feminicidio los delitos que siguen en frecuencia, hace nuevamente sentido que la vida e integridad corporal sean el segundo bien más afectado.

2.5.4. Modalidad de los Delitos

```

1 modalidad = dataframe["modalidad"].value_counts().head(15)
2
3 fig, ax = plt.subplots(figsize=(10, 10))
4 modalidad.plot(kind="barh", ax=ax, color=["#d62728", "#2ca02c"])
5
6 ax.set_title("Distribución de Delitos por Modalidad (Top 10, 2015-2025)", fontsize=10,
7             fontweight="bold")
8 ax.set_xlabel("Número de Registros")
9
10 for i, v in enumerate(modalidad.values):
11     ax.text(v + 500, i, f"{v:,}", va="center")

```

```

12 plt.tight_layout()
13 plt.show()

```

Listing 11: Código para generar gráfico de modalidades de los delitos




Figura 6: Modalidad de los Delitos en México (2015-2025)

Nuevamente, vemos también que hay una extraña coincidencia de valores después de la modalidad ‘En Accidente de Tráfico’, lo que sugiere y mantiene la idea de que existe un gran sesgo al momento de reportar correctamente todos los delitos.

También notamos que no existe una única forma de reportar los delitos con violencia, por lo que un registro puede pertenecer a un delito con esta modalidad y ser asignado a otra categoría (sobre todo en lo referente a los subtipos de robo).

2.5.5. Delincuencia por Año

```

1 dataframe["fecha"] = pd.to_datetime(dataframe["fecha"]) # add this line before groupby
2 temporal = dataframe.groupby("fecha")["incidencia_delictiva"].sum().sort_index()
3
4 fig, ax = plt.subplots(figsize=(10, 6))

```

```

5 ax.plot(temporal.index, temporal.values, linewidth=2, color="darkred")
6 ax.fill_between(temporal.index, temporal.values, alpha=0.2, color="red")
7
8 ax.set_title(
9     "Evolución Temporal de la Incidencia Delictiva (2015-2025)",
10     fontsize=13,
11     fontweight="bold",
12 )
13 ax.set_xlabel("Fecha")
14 ax.set_ylabel("Incidencia Delictiva Total")
15 ax.grid(True, alpha=0.2)
16 ax.xaxis.set_major_locator(mdates.YearLocator())
17 ax.xaxis.set_major_formatter(mdates.DateFormatter("%Y"))
18 ax.xaxis.set_minor_locator(mdates.MonthLocator())
19 ax.grid(True, which="major", alpha=0.3)
20 ax.grid(True, which="minor", alpha=0.1)
21 plt.tight_layout()
22 plt.show()
23 '''

```

Listing 12: Código para generar gráfico de delincuencia por año




Figura 7: Evolución Temporal de la Incidencia Delictiva en México (2015-2025)

Vemos que, desafortunadamente, no existe un decrecimiento notable en cuanto a la delincuencia en este periodo de tiempo. E incluso, desde 2022 hacia adelante es donde se alcanzan números más alto.

Veamos ahora como se ve ésta evolución dados los meses del año:


```
1 dataframe["fecha"] = pd.to_datetime(dataframe["fecha"])
2 dataframe["año"] = dataframe["fecha"].dt.year
3 dataframe["mes"] = dataframe["fecha"].dt.month
4
5 pivot_data = dataframe.groupby(["año", "mes"])["incidencia_delictiva"].sum().unstack()
6
7 fig, ax = plt.subplots(figsize=(10, 10))
8 sns.heatmap(
9     pivot_data,
10     cmap="YlOrRd",
11     annot=False,
12     fmt="d",
13     cbar_kws={"label": "Incidencia Delictiva"},
14     ax=ax,
15 )
16
17 ax.set_title(
18     "Patrón Mensual de Delincuencia por Año (2015-2025)", fontsize=13, fontweight="bold"
19 )
20 ax.set_xlabel("Mes")
21 ax.set_ylabel("Año")
22
23 plt.tight_layout()
24 plt.show()
```

Listing 13: Código para generar gráfico de delincuencia por mes




Figura 8: Patrón Mensual de Delincuencia por Año en México (2015-2025)

Vemos que en particular, de 2021 a 2025 el foco ha sido entre Marzo a Junio. Mientras que en años anteriores había sido de Mayo a Agosto (2015-2019). Lo que si es más fácil de notar con esto es que 2020 tiene los valores más bajos de todos los años del conjunto, lo que puede deberse a que la incidencia delictiva realmente bajó durante ese periodo o que directamente no se reportó por completo.

2.6. Detección de Outliers

Para detectar outliers lo que haremos será ocupar IQR. Por lo anterior notamos que la incidencia delictiva está fuertemente sesgada a la derecha por la CDMX y Edomex, ya que disparan los valores frente a estados pequeños. El z-score asume normalidad y los propios extremos inflan media y desviación, así que ocupar ésta medida reportaría resultados sesgados.

Para esto lo que haremos será ocupar la clase `OutlierDetector` que, como su nombre lo indica, identificará

los valores atípicos y luego usaremos su método `flag()` para aplicar ésta identificación a un nuevo dataframe.

```
1 det = OutlierDetector(dataframe, columns=["incidencia_delictiva"])
2 det.summary()
```

Listing 14: Código para detectar outliers en la incidencia delictiva

Tabla 6: Resumen de Detección de Outliers

idx	columna	Q1	Q3	IQR	Límite Inferior	Límite Superior	Número Outliers	de	% de Outliers
0	incidencia_delictiva	413952	0.0	9968.0	-39.0	65.0	63128		15.250077

Vemos que del total de registros, 63128 fueron identificados como outliers, lo que representa aproximadamente el 15.25 % del dataset. Esto es un porcentaje considerable, pero dado el contexto de la delincuencia en México, es comprensible que existan registros con incidencias extremadamente altas, especialmente en entidades como la CDMX y el EdoMex.

Sin embargo, es importante destacar que estos outliers no necesariamente representan errores en los datos, sino que reflejan la realidad de la incidencia delictiva en ciertas regiones y periodos. Por lo tanto, en lugar de eliminar estos registros, se ha optado por marcarlos con una nueva columna para su posterior análisis y consideración en cualquier modelado o interpretación de los datos. De esta manera, los datos se muestran como sigue:

```
1 det.flag()
```

Listing 15: Código para mostrar el dataset con la columna de outliers

Tabla 7: Muestra del dataset con columna de outliers

id	fecha	entidad	bien_juridico_afectado	tipo_delito	subtipo_delito	modalidad	incidencia_delictiva	incidencia_delictiva_is_outlier
0	2015-04-01	Aguascalientes	El patrimonio	Abuso de confianza	Abuso de confianza	Abuso de confianza	22	False
1	2015-08-01	Aguascalientes	El patrimonio	Abuso de confianza	Abuso de confianza	Abuso de confianza	40	False
2	2015-12-01	Aguascalientes	El patrimonio	Abuso de confianza	Abuso de confianza	Abuso de confianza	26	False
3	2015-01-01	Aguascalientes	El patrimonio	Abuso de confianza	Abuso de confianza	Abuso de confianza	41	False
4	2015-02-01	Aguascalientes	El patrimonio	Abuso de confianza	Abuso de confianza	Abuso de confianza	33	False

3. Modelos

Ahora, lo que buscamos es construir un modelo de regresión capaz de predecir la incidencia delictiva mensual a nivel estatal en México, utilizando como variables predictoras la entidad federativa, el bien jurídico afectado, el tipo y subtipo de delito, la modalidad y *features* temporales (año, mes, trimestre).

Para esto utilizaremos un **Random Forest Regressor** dentro de un pipeline de scikit-learn que incluye lo siguiente:

- **Preprocesamiento:** codificación One-Hot de variables categóricas y estandarización de variables numéricas.

- **Búsqueda de hiperparámetros:** Usaremos `RandomizedSearchCV` con validación cruzada de 3 pliegues, más eficiente que una búsqueda exhaustiva para este volumen de datos.
- **Transformación del objetivo:** Aplicaremos `log1p` a la variable objetivo para mitigar el sesgo observado en el EDA.

El dataset contiene $\sim 414,000$ registros de incidencia delictiva estatal, por lo que trabajar con todos estos registros es demasiado pesado en recursos. Es por esto que para este modelo trabajaremos con una muestra estratificada de 50,000 registros que preserva la proporción de tipos de delito.

El cuaderno de Jupyter Notebook que acompaña esta sección se encuentra disponible haciendo click [aquí](#).

```
1 import sys
2 from pathlib import Path
3
4 sys.path.insert(0, str(Path.cwd().parent))
5
6 import pandas as pd
7 import numpy as np
8 import matplotlib.pyplot as plt
9 import seaborn as sns
10
11 from sklearn.model_selection import train_test_split
12
13 from src.model.preprocesamiento import (
14     cargar_preparar_datos,
15     separar_features_target,
16     construir_preprocesador,
17 )
18 from src.model.entrenamiento import entrenar_random_forest
19 from src.model.evaluacion import evaluar_modelo, grafica_predicciones, grafica_residuales
20 from src.model.persistencia import guardar_modelo
21
22 pd.set_option("display.max_columns", 20)
23 pd.set_option("display.width", 140)
```

Listing 16: Carga de librerías y módulos del proyecto

3.1. Carga y preparación de datos

Cargamos el dataset limpio resultado del EDA y aplicamos un muestreo estratificado sobre la columna `tipo_delito` para reducir los $\sim 414,000$ registros a 50,000. Esto preserva la distribución de tipos de delito y reduce drásticamente el tiempo de entrenamiento sin comprometer la calidad del modelo, ya que Random Forest muestra rendimientos decrecientes con volúmenes de datos muy grandes.

Luego, separamos las features de nuestra variable objetivo: `incidencia_delictiva`, y aplicamos una transformación logarítmica con `log1p` para compensar el fuerte sesgo a la derecha observado en el EDA.

```
1 RUTA_DATOS = str(Path.cwd().parent / "data" / "processed" / "INM_estatal_dic25_clean.csv")
2
3 df = cargar_preparar_datos(RUTA_DATOS)
4 print(f"Muestra estratificada: {df.shape[0]:,} filas x {df.shape[1]} columnas")
5 df.head(3)
```

Listing 17: Carga y muestra estratificada del dataset

```
1 Muestra estratificada: 50,000 filas x 7 columnas
```

Tabla 8: Primeras filas del dataset muestreado

idx	fecha	entidad	bien_juridico_afectado	tipo_delito	subtipo_delito	modalidad	incidencia_delictiva
249379	2021-03-01	Puebla	El patrimonio	Otros delitos contra el patrimonio	Otros delitos contra el patrimonio	Otros delitos contra el patrimonio	26
57395	2016-09-01	Morelos	La vida y la Integridad corporal	Lesiones	Lesiones dolosas	No especificado	144
289658	2022-12-01	Quintana Roo	El patrimonio	Robo	Robo de vehículo automotor	Robo de coche de 4 ruedas Con violencia	11

La columna `fecha`, al ser de tipo `datetime`, se descompone en tres features numéricas: `anio`, `mes` y `trimestre`. Esto permite al modelo capturar tendencias temporales (tendencia anual, estacionalidad mensual y patrones por trimestre) sin introducir alta cardinalidad como haría un One-Hot de fechas individuales.

```
1 X, y = separar_features_target(df)
2
3 print(f"Features: {X.shape[1]} columnas")
4 print(f"Columnas: {list(X.columns)}")
5 print(f"\nTarget (log1p) - media: {y.mean():.3f}, std: {y.std():.3f}")
6 X.head(3)
```

Listing 18: Separación de features y target con transformación `log1p`

```
1 Features: 8 columnas
2 Columnas: ['entidad', 'bien_juridico_afectado', 'tipo_delito', 'subtipo_delito', 'modalidad',
3           ', 'anio', 'mes', 'trimestre']
4 Target (log1p) - media: 1.753, std: 1.990
```

Tabla 9: Primeras filas de las features (X) y el target transformado (y)

idx	entidad	bien_juridico_afectado	tipo_delito	subtipo_delito	modalidad	anio	mes	trimestre
249379	Puebla	El patrimonio	Otros delitos contra el patrimonio	Otros delitos contra el patrimonio	Otros delitos contra el patrimonio	2021	3	1
57395	Morelos	La vida y la Integridad corporal	Lesiones	Lesiones dolosas	No especificado	2016	9	3
289658	Quintana Roo	El patrimonio	Robo	Robo de vehículo automotor	Robo de coche de 4 ruedas Con violencia	2022	12	4

3.2. Preprocesamiento y división train/test

Separamos el 80 % de los datos para entrenamiento y el 20 % restante para prueba, con una semilla fija para reproducibilidad.

El preprocesador aplica dos transformaciones dentro del pipeline:

- **OneHotEncoder** sobre las columnas categóricas (`entidad`, `bien_juridico_afectado`, `tipo_delito`, `subtipo_delito`, `modalidad`). Esto para convertir cada categoría en una columna binaria. Se configura `handle_unknown=ignore` para que no falle si aparece una categoría nueva en el conjunto de prueba.
- **StandardScaler** sobre las columnas numéricas (`anio`, `mes`, `trimestre`) para estandarizar la media 0 y la desviación a 1.

Al integrar el preprocesador dentro del **Pipeline**, se evita el **data leakage**, pues así el **OneHotEncoder** y el **StandardScaler** se ajustan únicamente sobre los datos de entrenamiento en cada pliegue de la validación cruzada.

```

1 preprocessor = construir_preprocesador(X)
2
3 X_train, X_test, y_train, y_test = train_test_split(
4     X, y, test_size=0.20, random_state=42
5 )
6
7 print(f"Train: {X_train.shape[0]:,} filas")
8 print(f"Test:  {X_test.shape[0]:,} filas")

```

Listing 19: Construcción del preprocesador y división train/test

```

1 Train: 40,000 filas
2 Test:  10,000 filas

```

3.3. Entrenamiento del modelo

Utilizamos **RandomizedSearchCV** para buscar los mejores hiperparámetros del Random Forest. La razón principal por la que ocupamos esto y no **GridSearchCV** es porque el segundo evalúa todas las combinaciones posibles, mientras que el primero muestrea un número fijo de combinaciones aleatorias, lo que resulta más eficiente con datasets grandes como lo es el nuestro.

Ocuparemos el siguiente espacio de búsqueda:

Tabla 10: Espacio de búsqueda de hiperparámetros

Parámetro	Valores
<code>n_estimators</code>	100, 150
<code>max_depth</code>	15, None (sin límite)
<code>min_samples_split</code>	2, 5

junto a la siguiente configuración (la cual está hardcodeada en `src/model/entrenamiento.py`):

- `n_iter=8`: evalúa 8 combinaciones aleatorias de los parámetros.
- `cv=3`: validación cruzada con 3 pliegues.

- `scoring='r2'`: optimiza el coeficiente de determinación R^2 .
- `n_jobs=-1`: utiliza todos los núcleos disponibles del procesador.

```

1 search = entrenar_random_forest(X_train, y_train, preprocessor)
2
3 print(f"Mejores parámetros: {search.best_params_}")
4 print(f"Mejor R2 (CV):      {search.best_score_:.4f}")

```

Listing 20: Entrenamiento con RandomizedSearchCV

```

1 Fitting 3 folds for each of 8 candidates, totalling 24 fits
2 Mejores parámetros: {'model__n_estimators': 150, 'model__min_samples_split': 2, '
   model__max_depth': None}
3 Mejor R2 (CV):      0.9201

```

3.4. Evaluación del modelo

Evaluamos el rendimiento del mejor modelo sobre el conjunto de **prueba** (20% de los datos, no utilizado en el entrenamiento ni en la búsqueda de hiperparámetros) en base a las siguientes métricas:

- **MAE** (Error Absoluto Medio): error promedio en las mismas unidades que el target (escala log). Un valor de 0.38 indica que, en promedio, la predicción se desvía ~ 0.38 unidades logarítmicas del valor real.
- **MSE** (Error Cuadrático Medio): penaliza más los errores grandes.
- **RMSE** (Raíz del Error Cuadrático Medio): en la misma escala que el target, más interpretable que el MSE.
- **R^2** (Coeficiente de Determinación): proporción de la varianza explicada por el modelo. Un valor de 1.0 es predicción perfecta; 0.0 equivale a predecir siempre la media.

```

1 mejor_modelo = search.best_estimator_
2
3 metricas, y_pred = evaluar_modelo(mejor_modelo, X_test, y_test)
4 display(metricas)

```

Listing 21: Evaluación del modelo en el conjunto de prueba

Tabla 11: Métricas de evaluación del modelo en el conjunto de prueba

MAE	0.307301
MSE	0.262411
RMSE	0.512261
R2	0.932790

3.4.1. Importancia de features

El Random Forest permite extraer la **importancia** de cada feature, medida por cuánto reduce la impureza de los nodos del árbol. Dado que las 5 columnas categóricas fueron codificadas con One-Hot (generando cientos de columnas binarias), agrupamos la importancia por columna original para obtener una visión interpretable de qué variables son las que más contribuyen a las predicciones.

```
1 preprocessor = mejor_modelo.named_steps["preprocessor"]
2 feature_names = mejor_modelo[:-1].get_feature_names_out()
3 importances = mejor_modelo[-1].feature_importances_
4
5 cat_cols = [t[2] for t in preprocessor.transformers_ if t[0] == "cat"][0]
6 num_cols = [t[2] for t in preprocessor.transformers_ if t[0] == "num"][0]
7
8 def agrupar_feature(nombre):
9     if nombre.startswith("num_"):
10         return nombre[5:]
11     codificado = nombre[5:]
12     for col in cat_cols:
13         if codificado.startswith(col + "_"):
14             return col
15     return codificado
16
17 importance_df = pd.DataFrame({
18     "feature": feature_names,
19     "importance": importances
20 })
21 importance_df["grupo"] = importance_df["feature"].apply(agrupar_feature)
22
23 importancia_por_grupo = (
24     importance_df.groupby("grupo")["importance"]
25     .sum()
26     .sort_values(ascending=True)
27 )
28
29 plt.figure(figsize=(10, 6))
30 importancia_por_grupo.plot(kind="barh", color="steelblue")
31 plt.xlabel("Importancia acumulada")
32 plt.title("Importancia de features (agrupada por columna original)")
33 plt.tight_layout()
34 plt.show()
```

Listing 22: Cálculo y visualización de importancia de features




Figura 9: Importancia de features agrupada por columna original

3.5. Interpretación del Modelo

El modelo obtenido tiene las siguientes implicaciones:

- **$R^2 = 0.93$ — Alta capacidad predictiva.** El 93 % de la variación en la incidencia delictiva se explica por la combinación de entidad federativa, clasificación delictiva y variables temporales. Esto indica que el delito en México **no es un fenómeno aleatorio**: sigue patrones sistemáticos y repetibles que el modelo puede capturar.
- **Patrones geográficos.** Cada entidad federativa tiene un “perfil delictivo” distintivo. Estados como CDMX, Estado de México y Jalisco concentran volúmenes altos en ciertas categorías, mientras que estados como Colima o Tlaxcala muestran otras dinámicas. La feature **entidad** captura estas diferencias estructurales.
- **Patrones por clasificación delictiva.** La jerarquía **bien_juridico** → **tipo** → **subtipo** → **modalidad** permite al modelo distinguir entre categorías con volúmenes muy dispares. Por ejemplo, “homicidio” tiene incidencias bajas mientras que “robo” tiene incidencias altas; la modalidad (con/sin violencia) añade granularidad adicional.
- **Patrones temporales.** Las features **anio**, **mes** y **trimestre** capturan:
 - **Tendencia:** incrementos o disminuciones sostenidos a lo largo de los años.
 - **Estacionalidad:** ciclos mensuales o trimestrales (por ejemplo, incrementos en diciembre por temporadas vacacionales).

- **MAE ≈ 0.31 en escala log.** Para interpretar en unidades originales: $\exp(0.31) \approx 1.36$, lo que significa que el error promedio de predicción es de aproximadamente **36 % sobre el valor real**. Para un dataset con valores que van de decenas a miles de incidentes, esto es un margen de error razonable.

3.5.1. Análisis gráfico

Las gráficas de **Real vs Predicho** y de **residuales** permiten evaluar visualmente la calidad del ajuste. En un buen modelo, los puntos deben agruparse alrededor de la diagonal en la primera gráfica, y los residuales deben distribuirse simétricamente alrededor de cero en la segunda.

```
1 grafica_predicciones(y_test, y_pred)
2 grafica_residuales(y_test, y_pred)
```

Listing 23: Gráficas de predicciones y residuales




Figura 10: Gráfica de Real vs Predicho




Figura 11: Gráfica de residuales del modelo

3.6. Comparación con Línea Base

Para verificar que el modelo aporta valor real, lo comparamos contra un **DummyRegressor** que simplemente predice la media del target en cada caso. Si el Random Forest no supera significativamente a este modelo trivial, significaría que las features elegidas no tienen poder predictivo.

```
1 from sklearn.dummy import DummyRegressor
2 from sklearn.pipeline import Pipeline
3
4 baseline = Pipeline([
5     ("preprocessor", preprocessor),
6     ("model", DummyRegressor(strategy="mean"))
7 ])
8
9 baseline.fit(X_train, y_train)
10
11 baseline_metricas, _ = evaluar_modelo(baseline, X_test, y_test)
12 display(baseline_metricas)
```

Listing 24: Comparación con DummyRegressor como línea base

El DummyRegressor obtiene un $R^2 \approx 0$ (como es esperado, ya que predecir la media no explica variación). El Random Forest, con un R^2 significativamente mayor, demuestra que las features utilizadas capturan patrones reales de la incidencia delictiva.

Tabla 12: Métricas del DummyRegressor (línea base)

MAE	1.719015
MSE	3.904472
RMSE	3.904472
R2	-0.000034

3.7. Persistencia del modelo

Finalmente, guardamos el modelo entrenado en un archivo `.joblib` para su uso futuro en predicciones o análisis adicionales. Debido al peso del modelo final este se puede descargar desde [aquí](#) para evitar problemas de espacio en el repositorio y de ésta página.

Sin embargo, la instrucción para guardar el modelo es la siguiente:

```
1 guardar_modelo(mejor_modelo, "../models/modelo_incidencia_delictiva.joblib")
```

Listing 25: Guardado del modelo entrenado

3.8. Conclusiones sobre el modelo

El modelo de Random Forest logra predecir la incidencia delictiva estatal mensual con un R^2 de 0.93, superando ampliamente a la línea base ($R^2 \approx 0$). Esto confirma que:

1. La incidencia delictiva en México está fuertemente determinada por la ubicación geográfica, el tipo de delito y el momento en el tiempo. El 93% de la variación en la incidencia delictiva se explica por la combinación de ubicación geográfica, clasificación delictiva y momento en el tiempo. Esto descarta la hipótesis de que la criminalidad sea un fenómeno aleatorio o caótico: sigue patrones estables y recurrentes que un modelo de aprendizaje automático puede capturar con alta precisión.
2. Las variables utilizadas (entidad, clasificación delictiva, año/mes/trimestre) son suficientes para construir un modelo predictivo robusto. Sobre todo con estos datos más recientes, ya que el EDA mostró que la incidencia delictiva no ha decrecido entre 2015 y 2025, con un incremento notable desde 2022. Además, se observa estacionalidad: los picos se concentran entre marzo y junio en los últimos años (antes eran mayo-agosto). El modelo captura estos ciclos a través de las features `anio`, `mes` y `trimestre`, lo que permite identificar cuándo ocurren los periodos de mayor riesgo.
3. Los patrones delictivos son **estables y predecibles** en condiciones normales, lo cual es relevante para la planeación de políticas de seguridad. En particular, la clasificación delictiva es el predictor más potente, ya que la jerarquía `bien_juridico` $\rightarrow$ `tipo` $\rightarrow$ `subtipo` $\rightarrow$ `modalidad` permite distinguir entre categorías con volúmenes drásticamente diferentes. Como se vio en el EDA, Robo es el delito más reportado, pero la modalidad (con violencia, sin violencia, de vehículo automotor, etc.) añade granularidad que el modelo aprovecha para hacer predicciones más precisas.

3.8.1. Limitaciones

- El modelo aprende patrones históricos y no puede predecir anomalías como pandemias, crisis o cambios de política pública. El caso de 2020 (valores inusualmente bajos por COVID-19) es un ejemplo de evento que el modelo no anticiparía.
- Los datos dependen de denuncias ante el Ministerio Público, por lo que zonas con bajo reporte pueden tener valores artificialmente bajos.
- El modelo identifica correlaciones, no causalidades. Por ejemplo, saber que CDMX tiene alta incidencia de robo no explica por qué ocurre, lo cual es algo ajeno a lo que se realiza en este proyecto.

4. Clustering y Análisis de Componentes Principales

El objetivo de este módulo es identificar segmentos, perfiles y patrones latentes en la incidencia delictiva de las 32 entidades federativas de México mediante técnicas de agrupamiento no supervisado utilizando el algoritmo K-Means.

A diferencia de un análisis basado en el volumen total de delitos, el cual puede verse influenciado por factores como el tamaño poblacional o la concentración urbana de cada entidad, este estudio se centra en la proporción de participación de los siete Bienes Jurídicos Afectados registrados en cada estado. De esta forma, el análisis busca caracterizar la composición relativa de la actividad delictiva en cada entidad, independientemente de su magnitud absoluta.

Bajo este enfoque, la pregunta principal que guía el análisis es:

¿Qué tipo de delincuencia predomina en cada entidad federativa y qué estados comparten perfiles delictivos similares?

El cuaderno de Jupyter Notebook que acompaña esta sección se encuentra disponible haciendo click [aquí](#).

4.1. ¿Por qué se decidió usar K-Means?

Se seleccionó **K-Means** como algoritmo de agrupamiento debido a que las variables utilizadas corresponden a proporciones normalizadas de incidencia delictiva, generando un espacio de características continuo en el que la distancia euclidiana constituye una medida adecuada de similitud.

Adicionalmente, el análisis se realiza sobre un conjunto reducido de observaciones (32 entidades federativas), situación en la que los métodos basados en densidad pueden presentar una alta sensibilidad a la configuración de parámetros y producir agrupamientos poco estables.

Finalmente, K-Means genera centroides explícitos para cada grupo, lo que permite caracterizar e interpretar los perfiles criminológicos resultantes mediante el comportamiento promedio de los bienes jurídicos afectados en cada cluster.

4.2. Preparación de los Datos y Construcción de la Matriz de Proporciones

Con el fin de identificar patrones en la composición de la incidencia delictiva y evitar que los agrupamientos estuvieran determinados principalmente por el tamaño poblacional o el volumen total de delitos de cada entidad, se implementaron las siguientes transformaciones mediante la clase `CrimeClusteringPipeline`:

- **Agrupación por Bien Jurídico:** Los distintos tipos y subtipos de delitos se agruparon en las siete categorías de Bien Jurídico Afectado definidas en el conjunto de datos. Esto permitió reducir la dimensionalidad y obtener una representación más interpretable del fenómeno delictivo.
- **Normalización por Fila (Proporciones):** Para cada entidad federativa se calculó la proporción que representa cada bien jurídico respecto al total de delitos registrados en dicha entidad. Se usó la siguiente fórmula:

$$p_i = \frac{\text{Delitos}_i}{\sum_j \text{Delitos}_j}$$

De esta manera, cada estado quedó representado por un vector de siete proporciones cuya suma es igual a uno, permitiendo comparar la estructura relativa de la incidencia delictiva independientemente de su magnitud absoluta.

- **Estandarización (StandardScaler):** Aunque todas las variables fueron previamente transformadas a proporciones, los distintos bienes jurídicos presentan niveles de variabilidad diferentes entre entidades federativas. La estandarización permite que cada dimensión contribuya de forma equilibrada al cálculo de las distancias euclidianas utilizadas por K-Means, evitando que las categorías con mayor dispersión dominen el proceso de agrupamiento.

```
1 import sys
2 from pathlib import Path
3
4 # Resuelve el problema de las ubicaciones de los scripts
5 sys.path.insert(0, str(Path.cwd().parent))
6
7 import pandas as pd
8 import matplotlib.pyplot as plt
9 import seaborn as sns
10
11 from src import config
12 from src.data import DataRepository
13 from src.clustering import CrimeClusteringPipeline
```

```
14
15 # Tema visual por defecto del proyecto.
16 sns.set_theme(style=config.SEABORN_THEME, palette=config.PLOT_PALETTE)
17
18 # Cargar el dataset limpio
19 repo = DataRepository(config.PROCESSED_CSV)
20 dataframe = repo.load()
21
22 # Inicializar el pipeline de agrupamiento
23 clustering_pipe = CrimeClusteringPipeline()
24
25 # Transformar los datos y generar la matriz estandarizada
26 matrix_pct = clustering_pipe.fit_transform(dataframe)
```

Listing 26: Construcción de la matriz de proporciones y estandarización.

```
1 [Clustering] Matriz macro preparada con 32 estados y 7 variables (Bienes Jurídicos).
2 [Clustering] El plano visual (PCA 2D) captura el 55.32% de la varianza total de estas
   categorías
```

4.3. Consideración sobre la Dimensionalidad y Visualización

Con el propósito de visualizar los resultados del agrupamiento, se empleó un modelo de Análisis de Componentes Principales (PCA) configurado con dos componentes principales.

Es importante destacar que el algoritmo K-Means fue entrenado utilizando las siete variables originales estandarizadas, conservando así la totalidad de la información disponible para el proceso de agrupamiento. El PCA se utilizó únicamente como una técnica de reducción de dimensionalidad para representar gráficamente los resultados en un plano bidimensional.

La proyección obtenida mediante las dos primeras componentes principales explica el 55.32 % de la varianza total de los datos. Si bien esta representación no captura la totalidad de la estructura presente en el espacio original de siete dimensiones, proporciona una aproximación visual adecuada de los patrones principales y permite interpretar de forma intuitiva la separación entre los grupos identificados por K-Means. La información restante permanece contenida en las dimensiones no representadas gráficamente, pero sí fue considerada durante el proceso de agrupamiento.

4.4. Selección del Número Óptimo de Clusters

Para determinar la estructura de agrupamiento más adecuada de las entidades federativas, se evaluaron simultáneamente el Método del Codo (Inercia) y la evolución del Coeficiente de Silueta en un rango de entre 2 y 8 clústers.

```
1 #| label: k-clusters-selection
2 #| fig-cap: "Selección del número de clusters a usar"
3 # Calcular las métricas de Inercia y Silueta para rangos de K del 2 al 8
4 metrics = clustering_pipe.evaluate_k_options(max_k=8)
5
6 # Configurar el lienzo para mostrar ambas gráficas una al lado de la otra
7 fig, axes = plt.subplots(2, 1, figsize=(7, 7), dpi=config.PLOT_DPI)
8
9 # Gráfica izquierda: Método del Codo (Inercia)
10 sns.lineplot(x=metrics["k"], y=metrics["inertia"], marker="o", ax=axes[0], color="royalblue",
11             , linewidth=2)
12 axes[0].set_title("Curva del Codo")
13 axes[0].set_xlabel("Número de Grupos (K)")
14 axes[0].set_ylabel("Inercia (Suma de Cuadrados)")
15 axes[0].grid(True)
16
17 # Gráfica derecha: Evolución de la Silueta (Silhouette Score)
18 sns.lineplot(x=metrics["k"], y=metrics["silhouette"], marker="s", ax=axes[1], color="forestgreen",
19             , linewidth=2)
20 axes[1].set_title("Evolución del Coeficiente de Silueta")
21 axes[1].set_xlabel("Número de Grupos (K)")
22 axes[1].set_ylabel("Puntuación de Silueta")
23 axes[1].grid(True)
24
25 plt.tight_layout()
26 plt.show()
```

Listing 27: Selección del número óptimo de clusters (Inercia y Silhouette).




Figura 12: Selección del número de clusters mediante el método del codo y la evolución de la silueta (marcador de posición)

Analicemos estos resultados:

- **Coeficiente de Silueta:** Podemos observar un máximo local claramente definido en $K = 4$, indicando una buena combinación entre cohesión y separación de los grupos. Aunque el valor máximo absoluto se alcanza en $K = 8$, la mejora respecto al valor anterior es poco significativa como para usar este valor en lugar del anterior.
- **Método del Codo (Inercia):** La curva de inercia presenta una desaceleración apreciable en su tasa de disminución alrededor de $K = 4$, sugiriendo que incrementos posteriores en el número de clusters producen beneficios progresivamente menores.

Con base en ambos criterios seleccionamos $K = 4$ como la configuración final del modelo. Esta elección proporciona un equilibrio adecuado entre calidad estadística e interpretabilidad, permitiendo identificar perfiles delictivos diferenciados sin fragmentar excesivamente el conjunto de 32 entidades federativas analizadas.

4.5. Resultados de la Matriz de Proporciones y Perfil de Clusters

Una vez entrenado el modelo con $K = 4$, se obtuvo la matriz de proporciones promedio para cada cluster, lo que permitió caracterizar los perfiles delictivos predominantes en cada grupo de entidades federativas.

```

1 #|label: clustering-matrix-proportions
2 N_CLUSTERS_OPTIMO = 4
3
4 # Entrenar el modelo final en 7D y recuperar coordenadas PCA para graficar
5 df_clusters = clustering_pipe.fit_final_model(n_clusters=N_CLUSTERS_OPTIMO)
6
7 matrix_pct = clustering_pipe.prepare_matrix(dataframe)
8
9 # Pegamos la columna del cluster que calculó el modelo
10 matrix_pct['cluster'] = df_clusters.set_index('entidad')['cluster']
11
12 # Calculamos el promedio de cada delito para cada uno de los 4 grupos
13 resumen_clusters = matrix_pct.groupby('cluster').mean()
14
15 # Multiplicamos por 100 para visualizarlo como porcentaje limpio y transponemos para leerlo
    mejor
16 resumen_porcentual = (resumen_clusters * 100).round(2).T
17 resumen_porcentual

```

Listing 28: Entrenamiento final y resumen de proporciones por cluster.

Tabla 13: Proporción promedio de cada Bien Jurídico Afectado por cluster (en porcentaje)

cluster	0	1	2	3
bien_juridico_afectado				
El patrimonio	44.02	37.44	42.74	55.04
La familia	10.57	14.54	19.93	11.17
La libertad y la seguridad sexual	3.86	2.22	3.77	2.83
La sociedad	0.57	0.53	0.26	0.43
La vida y la Integridad corporal	18.74	11.61	13.47	11.08
Libertad personal	1.05	0.37	1.93	0.69
Otros bienes jurídicos afectados (del fuero común)	21.19	33.29	17.89	18.76

4.6. Interpretación de los Clusters

4.6.1. #0 – Perfil de Violencia contra las Personas

Este grupo se caracteriza por presentar la mayor participación relativa de delitos relacionados con **la vida y la integridad corporal (18.74%)**, así como el valor más elevado en **libertad y seguridad sexual (3.86%)**. En comparación con los demás grupos, la incidencia asociada a conductas violentas tiene un peso relativo mayor dentro de la composición delictiva total. Entre las entidades pertenecientes a este grupo se encuentran Campeche, Chiapas, Guerrero, Michoacán, Estado de México y Oaxaca.

4.6.2. #1 – Perfil Diversificado de Otros Bienes Jurídicos

La característica más distintiva de este grupo es la elevada participación de la categoría **Otros bienes jurídicos afectados (33.29 %)**, valor considerablemente superior al observado en los demás clústeres. Esto indica una distribución delictiva menos concentrada en categorías tradicionales como patrimonio o familia y una mayor presencia relativa de delitos clasificados en rubros complementarios del conjunto de datos. Este perfil está conformado por Coahuila, Guanajuato, Tabasco y Yucatán.

4.6.3. #2 – Perfil Familiar y de Libertad Personal

Este clúster presenta la mayor proporción de delitos contra **la familia (19.93 %)** y contra **la libertad personal (1.93 %)**, superando al resto de los grupos en ambas categorías. El resultado sugiere una mayor concentración relativa de problemáticas asociadas al entorno familiar y a conductas que afectan la libertad individual. Las entidades agrupadas bajo este perfil son Chihuahua, Durango, Hidalgo, Nayarit, Nuevo León, Quintana Roo, San Luis Potosí, Sinaloa, Sonora, Tamaulipas, Veracruz y Zacatecas.

4.6.4. #3 – Perfil Patrimonial

Este grupo concentra la mayor participación de delitos contra **el patrimonio (55.04 %)**, representando más de la mitad de la incidencia promedio del clúster. La composición observada refleja una predominancia de delitos patrimoniales, como robos, fraudes y conductas relacionadas con afectaciones económicas. Entre las entidades pertenecientes a este perfil se encuentran Aguascalientes, Baja California, Baja California Sur, Ciudad de México, Colima, Jalisco, Morelos, Puebla, Querétaro y Tlaxcala.

4.7. Tabla de Segmentación

Tabla 14: Segmentación de entidades por clúster y perfil identificado

Clúster	Perfil Identificado	Entidades Federativas Coincidentes
0	Perfil de Violencia contra las Personas	Campeche, Chiapas, Guerrero, Michoacán, Estado de México, Oaxaca
1	Perfil Diversificado / Otros Bienes Jurídicos	Coahuila, Guanajuato, Tabasco, Yucatán
2	Perfil Familiar y Libertad Personal	Chihuahua, Durango, Hidalgo, Nayarit, Nuevo León, Quintana Roo, San Luis Potosí, Sinaloa, Sonora, Tamaulipas, Veracruz, Zacatecas
3	Perfil Patrimonial	Aguascalientes, Baja California, Baja California Sur, Ciudad de México, Colima, Jalisco, Morelos, Puebla, Querétaro, Tlaxcala

4.8. Proyección PCA

A nivel general, la proyección bidimensional permite apreciar que los cuatro grupos identificados por K-Means muestran patrones diferenciados dentro del espacio de características, proporcionando una representación visual coherente con la estructura de agrupamiento obtenida por el modelo.

```
1
2 # Construir la visualización del Scatter Plot
3 plt.figure(figsize=(8, 4), dpi=config.PLOT_DPI)
4
5 sns.scatterplot(
6     data=df_clusters,
7     x="pca_1",
8     y="pca_2",
9     hue="cluster",
10    palette="tab10",
11    s=160,
12    style="cluster",
13    alpha=0.9
14 )
15
16 # Etiquetar cada punto con el nombre de su respectivo estado
17 for i in range(len(df_clusters)):
18     plt.text(
19         x=df_clusters["pca_1"][i] + 0.04,
20         y=df_clusters["pca_2"][i] + 0.04,
21         s=df_clusters["entidad"][i],
22         fontsize=8,
23         alpha=0.8
24     )
25
26 plt.title(f"Segmentación de Entidades Federativas en {N_CLUSTERS_OPTIMO} Perfiles Criminales
27           (Proyección PCA 2D)")
28 plt.xlabel("Componente Principal 1 (Varianza Visual)")
29 plt.ylabel("Componente Principal 2 (Varianza Visual)")
30
31 # Líneas de referencia en el origen
32 plt.axhline(0, color="grey", linestyle="--", alpha=0.3)
33 plt.axvline(0, color="grey", linestyle="--", alpha=0.3)
34
35 plt.tight_layout()
36 plt.show()
```

Listing 29: Visualización final de la segmentación en la proyección PCA 2D.




Figura 13: Visualización PCA 2D de la segmentación (marcador de posición)

Para comprender la geometría de las entidades federativas en la proyección PCA, analizamos la matriz de cargas (loadings), la cual indica la contribución y correlación lineal de cada Bien Jurídico Afectado con las dos primeras componentes principales (ejes del plano).

```
1 #| label: clustering-pca-loadings
2 # Extraer la matriz de loadings (componentes_ x variables)
3 loadings = clustering_pipe.pca.components_
4
5 # Construir un DataFrame elegante para analizar la composición
6 df_loadings = pd.DataFrame(
7     loadings.T, # Transponemos para que las variables queden en las filas
8     columns=["Componente Principal 1 (PC1)", "Componente Principal 2 (PC2)"],
9     index=clustering_pipe.features_names
10 )
11
12 df_loadings.round(3)
```

Listing 30: Extracción y presentación de loadings PCA.

Los coeficientes muestran que la Componente Principal 1 (PC1) está dominada por un contraste entre *El patrimonio* (carga positiva alta) y variables asociadas al entorno familiar y social, como *La familia* y *La libertad y la seguridad sexual* (cargas negativas). En consecuencia, las entidades ubicadas hacia la derecha del plano tienden a presentar una mayor proporción relativa de delitos patrimoniales, mientras que las ubicadas hacia la izquierda muestran una mayor participación relativa de las categorías familiares y sociales.

Por su parte, la Componente Principal 2 (PC2) está fuertemente influenciada por *Otros bienes jurídicos*

Tabla 15: Matriz de cargas (loadings) de las dos primeras componentes principales

Bien Jurídico Afectado	Componente Principal 1 (PC1)	Componente Principal 2 (PC2)
El patrimonio	0.567	-0.332
La familia	-0.564	0.030
La libertad y la seguridad sexual	-0.459	-0.137
La sociedad	-0.047	0.322
La vida y la integridad corporal	-0.095	-0.325
Libertad personal	-0.368	-0.450
Otros bienes jurídicos afectados	-0.058	0.677

afectados (0.677). Esto explica por qué las entidades del Cluster 1 como Yucatán, Coahuila, Guanajuato y Tabasco, aparecen desplazadas hacia la parte superior de la gráfica, pues comparten una participación relativamente elevada de esa categoría respecto al resto del país.

La matriz de cargas también ayuda a interpretar el caso de Tlaxcala, que aparece aislado en la parte inferior derecha. Su ubicación sugiere una combinación de proporciones delictivas distinta a la observada en la mayoría de las entidades de su mismo clúster, aun cuando mantiene una fuerte orientación patrimonial.

La proximidad o aparente solapamiento de algunos puntos pertenecientes a distintos grupos dentro de la proyección bidimensional es un comportamiento esperado ya que la representación mediante PCA conserva únicamente el 55.32 % de la varianza total de los datos, dejando fuera aproximadamente el 44.68 % de la información contenida en las dimensiones restantes.

4.9. Perfiles bajo la Proyección PCA

4.9.1. #1 - Perfil Diversificado

Este grupo, conformado por Yucatán, Coahuila, Guanajuato y Tabasco, es el más claramente distinguible dentro de la proyección PCA, desplazándose hacia la región superior del plano. Esta separación visual resulta consistente con el análisis de los perfiles promedio, ya que corresponde al clúster con la mayor participación de la categoría **Otros bienes jurídicos afectados**, característica que lo diferencia del resto de las entidades federativas.

4.9.2. #0 y #2 - Perfiles de Violencia y Entorno Familiar

Ambos grupos ocupan principalmente la región central de la proyección y presentan algunos estados relativamente próximos entre sí. Esta situación sugiere que comparten ciertas características en las dos primeras componentes principales. No obstante, dicha cercanía la debemos interpretar con cuidado ya que la agrupación definitiva fue realizada en el espacio original de siete dimensiones, donde existen diferencias suficientes para que K-Means los clasifique en perfiles distintos.

4.9.3. #3 - Perfil Patrimonial

Este grupo exhibe un núcleo relativamente compacto en la región derecha del plano, donde se concentran entidades como Ciudad de México, Aguascalientes, Querétaro y Jalisco. La cohesión observada resulta consistente con su perfil predominantemente patrimonial, caracterizado por una elevada participación de delitos contra el patrimonio. Adicionalmente, destaca el caso de **Tlaxcala**, que aparece visualmente separado del núcleo principal del grupo. Aunque comparte la misma clasificación patrimonial, su ubicación sugiere una combinación de proporciones delictivas distinta a la observada en el resto de las entidades del clúster.

Podemos notar que algunos puntos pertenecientes a distintos grupos aparecen próximos entre sí dentro de la proyección bidimensional. Este comportamiento es esperado, ya que la representación mediante PCA conserva únicamente el 55.32 % de la varianza total de los datos, dejando fuera aproximadamente el 44.68 % de la información contenida en las dimensiones restantes.

5. Conclusiones

El análisis integral de la incidencia delictiva en México entre 2015 y 2025 demuestra que la criminalidad no es un fenómeno aleatorio, sino que sigue patrones sistemáticos determinados por la ubicación geográfica, la clasificación delictiva y las condiciones temporales. El modelo predictivo de Random Forest alcanzó un R^2 de 0.93, lo que confirma que el 93 % de la variación en la incidencia delictiva puede explicarse mediante la entidad federativa, el tipo de delito y variables como año, mes y trimestre. Esto descarta la hipótesis de caos o impredecibilidad: los patrones delictivos son estables y recurrentes bajo condiciones normales, lo cual es relevante para la planeación de políticas públicas de seguridad.

El análisis exploratorio reveló que la incidencia delictiva no ha disminuido en más de una década, con un incremento notable a partir de 2022, y que los picos se concentran entre marzo y junio en los años recientes. El robo es el delito más reportado a nivel nacional, mientras que estados como el Estado de México, CDMX y Jalisco lideran en volumen absoluto. El clustering identificó cuatro perfiles delictivos claramente diferenciados: un perfil de violencia contra las personas (sur y centro-pacífico), uno patrimonial (áreas urbanas de alta densidad), uno familiar y de libertad personal, y uno diversificado. Estos perfiles permiten entender que cada entidad federativa enfrenta dinámicas criminales distintas que requieren estrategias de prevención diferenciadas.

Entre las limitaciones del proyecto destacan que el modelo aprende de patrones históricos y no puede anticipar eventos anómalos como pandemias o crisis políticas, y que los datos dependen de denuncias ante el Ministerio Público, lo que puede generar subreporte en ciertas zonas. Además, el modelo identifica correlaciones, no causalidades: saber que CDMX tiene alta incidencia de robo no explica por qué ocurre.

No obstante, el proyecto logra su objetivo principal de proporcionar una herramienta analítica que permite

identificar los delitos más probables por estado y predecir su incidencia, ofreciendo una base sólida para la toma de decisiones en materia de seguridad pública.