

UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO

FACULTAD DE CIENCIAS



ALMACENES Y MINERÍA DE DATOS

PROYECTO FINAL - MINERÍA DE DATOS APLICADA A MÉXICO

Alumnos:

- Méndez Ávila Luis Geovanni 317143980
- Paredes Zamudio Luis Daniel 318159926
- Sánchez Rosas Roberto Samuel 318355159

Profesora: L. en C.C. Jessica Santizo Galicia

10 de Junio de 2026

Índice

1. Introducción

No es noticia nueva de que México sufre de un serio problema de delincuencia. Y esto, desgraciadamente, no ha disminuido considerablemente en 10 años a la fecha. Pero la realidad es que distintos estados de la república sufren de delitos en particular que, aunque presentes en otros lugares, no son el principal foco del lugar.

Nuestro objetivo al analizar la incidencia delictiva es poder identificar no solo cuáles son éstos delitos los más preliminares en cada estado, si no también poder crear un modelo que establezca cual es delito más probable que pueda sufrir un ciudadano de un estado en particular.

Desgraciadamente, todos somos propensos a sufrirlos, pero identificarlos no solo nos permite a nosotros como habitantes poder prepararnos para evitarlos lo más que se pueda, como le puede servir a las autoridades componentes para concientizar y, utópicamente, idear soluciones que reduzcan verdaderamente la epidemia de delincuencia que sufre el país.

Este dataset pertenece a la [Plataforma Nacional de Datos Abiertos Mexicana](#) y fue creado por el Secretariado Ejecutivo del Sistema Nacional de Seguridad Pública (SESNSP). Este dataset, nombrado simplemente como "Incidencia Delictiva", puede descargarse siguiendo [este enlace](#).

2. Análisis Exploratorio de Datos

Haremos un EDA para conocer el dataset en profundir y poder identificar patrones, tendencias y relaciones entre las variables. Esto nos permitirá tomar decisiones informadas sobre cómo abordar el problema de la incidencia delictiva más adelante en el proyecto, principalmente para crear el modelo de predicción adecuado a este problema.

Para esto, haremos limpieza, análisis estadístico, detección de outliers y visualización de los datos.

2.1. Diccionario de Datos

A continuación se muestra el bloque de código usado para cargar y revisar el diccionario de datos:

```
1 #| label: data-load-dictionary
2 import sys
3 from pathlib import Path
4
5 # Resuelve el problema de las ubicaciones de los scripts
6 sys.path.insert(0, str(Path.cwd().parent))
7
8 import pandas as pd
9 import matplotlib.pyplot as plt
10 import seaborn as sns
```

```
11
12 from src import config
13 from src.data import DataRepository
14 from src.preprocessing import PreprocessingPipeline
15 from src.eda import StatisticsAnalyzer, OutlierDetector
16
17 # Tema visual por defecto del proyecto.
18 sns.set_theme(style=config.SEABORN_THEME, palette=config.PLOT_PALETTE)
19 pd.set_option("display.max_columns", 20)
20 pd.set_option("display.width", 140)
21 pd.set_option("display.max_colwidth", 200)
22
23 repo = DataRepository()
24 dataframe = repo.load()
25 repo.dictionary()
```

Listing 1: Carga y visualización del diccionario de datos.

2.2. Overview del Dataset

El bloque siguiente muestra una vista general del dataframe cargado:

```
1 #| label: dataset-overview
2 dataframe
```

Listing 2: Vista general del dataset.

El dataset contiene 413,952 registros que abarcan desde enero de 2015 hasta diciembre de 2025 (11 años). Los datos están organizados a nivel estatal con granularidad mensual (32 entidades $\times$ 40+ tipos de delito $\times$ 132 meses), lo que nos permite hacer análisis longitudinales de la evolución del delito en cada estado.

2.3. Calidad y Limpieza de los Datos

Haremos lo siguiente con el dataset original:

- Borramos las columnas `anio` y `mes` para poder trabajar únicamente con fecha. Posteriormente, ésta última pasará a ser de tipo `datetime`.
- `entidad_federativa` es un duplicado de `entidad`, por lo que borramos ésta columna.
- `clave_entidad` no nos es de utilidad al ya tener el nombre de las entidades, por lo que borramos ésta columna.
- Analizamos el dataset en busca de duplicados y valores nulos.

- Consideraremos que una entrada es inválida si tiene valores NaN en `incidencia_delictiva`, `fecha` y `entidad`. Una vez detectadas, serán eliminadas.
- Por revisión manual, vemos que algunos estados tienen su nombre completo, como **Veracruz de Ignacio de la Llave**. Acortaremos el nombre de estos estados para una visualización más limpia de la información.

El código de preprocesamiento usado fue:

```
1 #| label: data-cleaning-quality
2 cleaning_pipeline = PreprocessingPipeline(
3     drop_columns=["anio", "clave_ent", "mes", "entidad_federativa"]
4 )
5 clean_dataset = cleaning_pipeline.run(dataframe)
6 # reorganizamos las columnas para tener la fecha como columna inicial del dataset
7 clean_dataset = clean_dataset.iloc[:, [5, 0, 1, 2, 3, 4, 6]]
8 cleaning_pipeline.save(clean_dataset)
```

Listing 3: Limpieza y preprocesamiento del dataset.

Vemos que, a pesar de ser un dataset de origen gubernamental, éste no contiene duplicados ni entradas inválidas. Por lo que solo se realizó la conversión de fechas y la eliminación de las columnas con las que no trabajaremos.

2.4. Estadísticas Descriptivas Numéricas

En base a la naturaleza de nuestro dataset, el análisis estadístico se centrará principalmente en la variable `incidencia_delictiva`, que representa el número de delitos reportados para cada combinación de estado, tipo de delito y fecha.

Veamos algunas estadísticas descriptivas clave para esta variable (código):

```
1 #| label: descriptive-statistics
2 repo = DataRepository("../data/processed/INM_estatal_dic25_clean.csv")
3 dataframe = repo.load()
4 stats = StatisticsAnalyzer(dataframe)
5 stats.numeric_stats()
```

Listing 4: Cálculo de estadísticas descriptivas numéricas.

La media (52.5) es muy superior a la mediana (2.0), lo que indica un sesgo severo hacia la derecha. La mayoría de los registros tienen baja incidencia (2 delitos), pero algunos delitos registran valores enormes (siendo 9,968 el valor máximo). Sin embargo, en un contexto real, la CDMX y el EdoMex son probablemente las entidades con valores más altos y más concentrados debido a su población y urbanización. Validaremos esto más adelante.

En ese sentido, esto no sería (necesariamente) un sesgo en los datos, si no que refleja disparidades geográficas genuinas en la delincuencia. Sin embargo, eso no significa que, nuevamente en un contexto real, no se reporte de la misma manera en otros estados.

2.4.1. Histogramas de incidencia delictiva

Código usado para generar histogramas (se generan dos subplots: escala original y escala logarítmica):

```
1  #| label: delective-incidence-histograms
2  #| fig-cap: "Histogramas de Incidencia Delictiva por Estado"
3
4  fig, axes = plt.subplots(2, 1, figsize=(10, 12))
5
6  sns.histplot(
7      data=dataframe,
8      x="incidencia_delictiva",
9      bins=50,
10     color="crimson",
11     ax=axes[0]
12 )
13 axes[0].set_title("A) Histograma en Escala Original\n(Sesgo Extremo hacia la Derecha)",
14                  fontsize=12, fontweight="bold")
15 axes[0].set_xlabel("Número de Delitos por Registro")
16 axes[0].set_ylabel("Frecuencia (Cantidad de Registros)")
17 axes[0].grid(True, linestyle="--", alpha=0.5)
18
19 df_non_zero = dataframe[dataframe["incidencia_delictiva"] > 0]
20 sns.histplot(
21     data=df_non_zero,
22     x="incidencia_delictiva",
23     kde=True,
24     log_scale=True,
25     color="darkblue",
26     ax=axes[1]
27 )
28 axes[1].set_title("B) Histograma en Escala Logarítmica\n(Estructura Interna de la Incidencia
29                    )", fontsize=12, fontweight="bold")
30 axes[1].set_xlabel("Número de Delitos por Registro (Escala Logarítmica)")
31 axes[1].set_ylabel("Frecuencia (Cantidad de Registros)")
32 axes[1].grid(True, linestyle="--", alpha=0.5)
33
34 plt.suptitle("Análisis de Distribución de la Incidencia Delictiva en México", fontsize=15,
35              fontweight="bold", y=1.02)
36 plt.tight_layout()
```

```
35 plt.show()
```

Listing 5: Histogramas de incidencia delictiva (escala original y log).



Figura 1: Histogramas de Incidencia Delictiva por Estado (marcador de posición)

El primer gráfico muestra una distribución con un sesgo hacia la derecha extremadamente severa. La inmensa mayoría de los registros del dataset se concentran de forma masiva en valores muy cercanos a cero (recordemos que la mediana del dataset es de 2 delitos por registro). Esto se debe a que existen muchas categorías de delitos poco comunes o entidades con menor población que reportan frecuentemente cero u muy pocas incidencias mensuales de estos delitos no tan comunes. Visualmente, esto genera una gran "pared" en el extremo izquierdo y una cola invisible infinitamente larga hacia la derecha que se extiende hasta el valor máximo de 9,968.

Con el segundo gráfico queremos reevaluar la distribución real que queda oculta bajo el sesgo. Para esto se aplicó una escala logarítmica sobre el eje de las abscisas (filtrando los registros con delitos). Esto nos da una distribución con dos picos:

- El primero muestra cuando se registran de 1 a 3 delitos en promedio. Esto representa la gran masa de reportes delictivos de baja ocurrencia o zonas con baja densidad demográfica.

- El segundo muestra cuando se registran de 30 a 100 delitos en promedio. Esto representa la acumulación de delitos altamente recurrentes (como variantes de robos) en zonas urbanas o de alta incidencia.

2.5. Estadísticas Descriptivas Categóricas

```
1 #| label: categorical-stats
2 stats.categorical_stats()
```

Listing 6: Cálculo de estadísticas descriptivas categóricas.

En cuanto a las variables categóricas del conjunto de datos podemos notar hechos bastante interesantes a pesar de la inmensidad del dataset:

- El dataset es de 11 años, sin embargo, solo hay 132 fechas únicas, con la fecha inicial siendo el 01 de enero de 2015
- La moda del dataset tiene algunos resultados curiosos. Este conjunto de datos es simétrico para cada estado, ya que existen 12936 líneas para c/u. Entonces, al querer calcular la moda se toma el valor inicial de manera alfabética y resulta ser Aguascalientes. Sin embargo, esto no significa que sea la entidad con mayor apariciones del dataset.
- Lo anterior pasa de igual manera con la fecha, ya que toma la primera fecha del dataset para calcular este valor.
- El dataset reporta 40 tipos de delitos únicos reportados, con Robo siendo la categoría principal.

Veamos ahora un análisis más detallado de las variables categóricas.

2.5.1. Delitos más Comunes

```
1 #| label: most-common-crimes
2 #| fig-cap: "Delitos más Comunes en México (2015-2025)"
3 crime_counts = dataframe["tipo_delito"].value_counts().head(10)
4
5 fig, ax = plt.subplots(figsize=(10, 4))
6 crime_counts.plot(kind="barh", ax=ax, color="steelblue")
7 ax.set_title("Top 10 Tipos de Delito", fontsize=13, fontweight="bold")
8 ax.set_xlabel("Número de Registros")
9 ax.invert_yaxis()
10
11 # Añade valores en las barras
12 for i, v in enumerate(crime_counts.values):
13     ax.text(v + 1000, i, f"{v:,}", va="center", fontsize=10)
14
15 plt.tight_layout()
```



```
16 plt.show()
```

Listing 7: Cálculo y gráfico de los delitos más comunes.



Figura 2: Top 10 Tipos de Delito (marcador de posición)

Como se mencionaba en la tabla anterior, robo es el delito más reportado, seguido de homicidio y lesiones. Algo a recordar es que aunque los feminicidios son también homicidios éstos están en una categoría separada debido al motivo por el que ocurren. Vemos también que hay una extraña coincidencia de valores entre Abuso de Confianza, Daño a la Propiedad, Despojo, Extorsión y Fraude, lo que sugiere un sesgo al momento de reportar estos delitos por parte de la autoridad (por ejemplo, cifras redondeadas, reportes nulos, etc.)

2.5.2. Incidencia Delictiva por Estado

```
1 #| label: crime-by-state
2 #| fig-cap: "Incidencia Delictiva Total por Estado (2015-2025)"
3 from matplotlib.ticker import StrMethodFormatter
4
5 entidad_counts = (
6     dataframe.groupby("entidad")["incidencia_delictiva"]
7     .sum()
8     .sort_values(ascending=False)
```

```

9     .head(10)
10 )
11
12 fig, ax = plt.subplots(figsize=(10, 6))
13 bars = ax.bar(entidad_counts.index, entidad_counts.values, color="coral")
14 # Formato del eje Y con separadores de miles y sin decimales
15 ax.yaxis.set_major_formatter(StrMethodFormatter("{x:, .0f}"))
16 # Agregamos los valores reales arriba de cada barra con separadores de miles
17 ax.bar_label(bars, fmt="{:, .0f}", padding=3, fontsize=10, fontweight="bold")
18
19 ax.set_title(
20     "Incidencia Delictiva Total por Entidad (Top 10) - 2015 a 2025",
21     fontsize=15,
22     fontweight="bold",
23     pad=15,
24 )
25 ax.set_ylabel("Total de Delitos", fontsize=12)
26 ax.set_xlabel("Entidad Federativa", fontsize=12)
27 ax.tick_params(axis="x", rotation=40)
28
29 plt.tight_layout()
30 plt.show()

```

Listing 8: Cálculo y gráfico de incidencia delictiva total por estado.

Nuestra sospecha anterior que la EdoMex y la CDMX son los estados con más reportes es correcta. Vemos que le siguen Jalisco, Guanajuato y Baja California y que, a pesar de la moda, Aguascalientes no figura dentro de los estados con más delitos reportados.

```

1 #| label: crime-heatmap
2 # | fig-cap: "Mapa de Calor de Incidencia Delictiva por Entidad y Tipo de Delito (Top 10
3   Delitos y Top 15 Entidades)"
4 top_crimes = dataframe["tipo_delito"].value_counts().head(10).index
5 top_entities = dataframe["entidad"].value_counts().head(10).index
6
7 filtered_df = dataframe[dataframe["tipo_delito"].isin(top_crimes) & dataframe["entidad"].
8   isin(top_entities)]
9
10 pivot = filtered_df.pivot_table(
11     values="incidencia_delictiva", index="entidad", columns="tipo_delito", aggfunc="sum"
12 )
13
14 fig, ax = plt.subplots(figsize=(10, 10))
15 sns.heatmap(
16     pivot,
17     cmap="RdYlGn_r",

```



Figura 3: Incidencia Delictiva Total por Entidad (marcador de posición)

```
16     annot=True,
17     fmt=",.0f", # Agregamos la coma para que los números dentro del mapa tengan comas (ej.
18                 1,234,567)
19     cbar_kws={"label": "Incidencia"},
20     ax=ax,
21 )
22
23 cbar = ax.collections[0].colorbar
24 # aplicamos formato con comas de miles y sin decimales
25 cbar.ax.yaxis.set_major_formatter(StrMethodFormatter('{x:,.0f}'))
26
27 ax.set_title(
28     "Incidencia por Entidad y Tipo de Delito",
29     fontsize=12,
30     fontweight="bold",
31     pad=15
```

```
31 )  
32  
33 plt.tight_layout()  
34 plt.show()
```

Listing 9: Mapa de calor de incidencia por entidad y tipo de delito.



Figura 4: Mapa de calor de incidencia por entidad y tipo de delito (marcador de posición)

3. Modelos

4. Clustering y Análisis de Componentes Principales

El objetivo de este módulo es identificar segmentos, perfiles y patrones latentes en la incidencia delictiva de las 32 entidades federativas de México mediante técnicas de agrupamiento no supervisado utilizando el algoritmo K-Means.

A diferencia de un análisis basado en el volumen total de delitos, el cual puede verse influenciado por factores como el tamaño poblacional o la concentración urbana de cada entidad, este estudio se centra en la proporción de participación de los siete Bienes Jurídicos Afectados registrados en cada estado. De esta forma, el análisis busca caracterizar la composición relativa de la actividad delictiva en cada entidad, independientemente de su magnitud absoluta.

Bajo este enfoque, la pregunta principal que guía el análisis es:

¿Qué tipo de delincuencia predomina en cada entidad federativa y qué estados comparten perfiles delictivos similares?

4.1. ¿Por qué se decidió usar K-Means?

Se seleccionó **K-Means** como algoritmo de agrupamiento debido a que las variables utilizadas corresponden a proporciones normalizadas de incidencia delictiva, generando un espacio de características continuo en el que la distancia euclidiana constituye una medida adecuada de similitud.

Adicionalmente, el análisis se realiza sobre un conjunto reducido de observaciones (32 entidades federativas), situación en la que los métodos basados en densidad pueden presentar una alta sensibilidad a la configuración de parámetros y producir agrupamientos poco estables.

Finalmente, K-Means genera centroides explícitos para cada grupo, lo que permite caracterizar e interpretar los perfiles criminológicos resultantes mediante el comportamiento promedio de los bienes jurídicos afectados en cada cluster.

4.2. Preparación de los Datos y Construcción de la Matriz de Proporciones

Con el fin de identificar patrones en la composición de la incidencia delictiva y evitar que los agrupamientos estuvieran determinados principalmente por el tamaño poblacional o el volumen total de delitos de cada entidad, se implementaron las siguientes transformaciones mediante la clase **CrimeClusteringPipeline**:

- **Agrupación por Bien Jurídico:** Los distintos tipos y subtipos de delitos se agruparon en las siete categorías de Bien Jurídico Afectado definidas en el conjunto de datos. Esto permitió reducir la dimensionalidad y obtener una representación más interpretable del fenómeno delictivo.
- **Normalización por Fila (Proporciones):** Para cada entidad federativa se calculó la proporción que representa cada bien jurídico respecto al total de delitos registrados en dicha entidad. Se usó la siguiente fórmula:

$$p_i = \frac{\text{Delitos}_i}{\sum_j \text{Delitos}_j}$$

De esta manera, cada estado quedó representado por un vector de siete proporciones cuya suma es igual a uno, permitiendo comparar la estructura relativa de la incidencia delictiva independientemente de su magnitud absoluta.

- **Estandarización (StandardScaler):** Aunque todas las variables fueron previamente transformadas a proporciones, los distintos bienes jurídicos presentan niveles de variabilidad diferentes entre entidades federativas. La estandarización permite que cada dimensión contribuya de forma equilibrada al cálculo de las distancias euclidianas utilizadas por K-Means, evitando que las categorías con mayor dispersión dominen el proceso de agrupamiento.

El siguiente bloque muestra el código empleado para cargar los datos e inicializar el pipeline de clustering:

```
1 #| label: clustering-pipe-matrix
2 import sys
3 from pathlib import Path
4
5 # Resuelve el problema de las ubicaciones de los scripts
6 sys.path.insert(0, str(Path.cwd().parent))
7
8 import pandas as pd
9 import matplotlib.pyplot as plt
10 import seaborn as sns
11
12 from src import config
13 from src.data import DataRepository
14 from src.clustering import CrimeClusteringPipeline
15
16 # Tema visual por defecto del proyecto.
17 sns.set_theme(style=config.SEABORN_THEME, palette=config.PLOT_PALETTE)
18
19 # Cargar el dataset limpio
20 repo = DataRepository(config.PROCESSED_CSV)
21 dataframe = repo.load()
22
23 # Inicializar el pipeline de agrupamiento
24 clustering_pipe = CrimeClusteringPipeline()
25
26 # Transformar los datos y generar la matriz estandarizada
27 matrix_pct = clustering_pipe.fit_transform(dataframe)
```

Listing 10: Construcción de la matriz de proporciones y estandarización.

4.3. Consideración sobre la Dimensionalidad y Visualización

Con el propósito de visualizar los resultados del agrupamiento, se empleó un modelo de Análisis de Componentes Principales (PCA) configurado con dos componentes principales.

Es importante destacar que el algoritmo K-Means fue entrenado utilizando las siete variables originales estandarizadas, conservando así la totalidad de la información disponible para el proceso de agrupamiento. El PCA se utilizó únicamente como una técnica de reducción de dimensionalidad para representar gráficamente los resultados en un plano bidimensional.

La proyección obtenida mediante las dos primeras componentes principales explica el 55.32% de la varianza total de los datos. Si bien esta representación no captura la totalidad de la estructura presente en el espacio original de siete dimensiones, proporciona una aproximación visual adecuada de los patrones principales y permite interpretar de forma intuitiva la separación entre los grupos identificados por K-Means. La información restante permanece contenida en las dimensiones no representadas gráficamente, pero sí fue considerada durante el proceso de agrupamiento.

4.4. Selección del Número Óptimo de Clusters

Para determinar la estructura de agrupamiento más adecuada de las entidades federativas, se evaluaron simultáneamente el Método del Codo (Inercia) y la evolución del Coeficiente de Silueta en un rango de entre 2 y 8 clústers.

```
1  #| label: k-clusters-selection
2  #| fig-cap: "Selección del número de clusters a usar"
3  # Calcular las métricas de Inercia y Silueta para rangos de K del 2 al 8
4  metrics = clustering_pipe.evaluate_k_options(max_k=8)
5
6  # Configurar el lienzo para mostrar ambas gráficas una al lado de la otra
7  fig, axes = plt.subplots(2, 1, figsize=(7, 7), dpi=config.PLOT_DPI)
8
9  # Gráfica izquierda: Método del Codo (Inercia)
10 sns.lineplot(x=metrics["k"], y=metrics["inertia"], marker="o", ax=axes[0], color="royalblue",
11              , linewidth=2)
12 axes[0].set_title("Curva del Codo")
13 axes[0].set_xlabel("Número de Grupos (K)")
14 axes[0].set_ylabel("Inercia (Suma de Cuadrados)")
15 axes[0].grid(True)
16
17 # Gráfica derecha: Evolución de la Silueta (Silhouette Score)
18 sns.lineplot(x=metrics["k"], y=metrics["silhouette"], marker="s", ax=axes[1], color="
19              forestgreen", linewidth=2)
20 axes[1].set_title("Evolución del Coeficiente de Silueta")
21 axes[1].set_xlabel("Número de Grupos (K)")
```

```
20 axes[1].set_ylabel("Puntuación de Silueta")
21 axes[1].grid(True)
22
23 plt.tight_layout()
24 plt.show()
```

Listing 11: Selección del número óptimo de clusters (Inercia y Silhouette).



Figura 5: Selección del número de clusters mediante el método del codo y la evolución de la silueta (marcador de posición)

Analicemos estos resultados:

- **Coefficiente de Silueta:** Podemos observar un máximo local claramente definido en $K = 4$, indicando una buena combinación entre cohesión y separación de los grupos. Aunque el valor máximo absoluto se alcanza en $K = 8$, la mejora respecto al valor anterior es poco significativa como para usar este valor en lugar del anterior.
- **Método del Codo (Inercia):** La curva de inercia presenta una desaceleración apreciable en su tasa de disminución alrededor de $K = 4$, sugiriendo que incrementos posteriores en el número de clusters producen beneficios progresivamente menores.

Con base en ambos criterios seleccionamos $K = 4$ como la configuración final del modelo. Esta elección proporciona un equilibrio adecuado entre calidad estadística e interpretabilidad, permitiendo identificar perfiles delictivos diferenciados sin fragmentar excesivamente el conjunto de 32 entidades federativas analizadas.

4.5. Resultados de la Matriz de Proporciones y Perfil de Clusters

Una vez entrenado el modelo con $K = 4$, se obtuvo la matriz de proporciones promedio para cada cluster, lo que permitió caracterizar los perfiles delictivos predominantes en cada grupo de entidades federativas.

```
1 #|label: clustering-matrix-proportions
2 N_CLUSTERS_OPTIMO = 4
3
4 # Entrenar el modelo final en 7D y recuperar coordenadas PCA para graficar
5 df_clusters = clustering_pipe.fit_final_model(n_clusters=N_CLUSTERS_OPTIMO)
6
7 matrix_pct = clustering_pipe.prepare_matrix(dataframe)
8
9 # Pegamos la columna del cluster que calculó el modelo
10 matrix_pct['cluster'] = df_clusters.set_index('entidad')['cluster']
11
12 # Calculamos el promedio de cada delito para cada uno de los 4 grupos
13 resumen_clusters = matrix_pct.groupby('cluster').mean()
14
15 # Multiplicamos por 100 para visualizarlo como porcentaje limpio y transponemos para leerlo
    mejor
16 resumen_porcentual = (resumen_clusters * 100).round(2).T
17 resumen_porcentual
```

Listing 12: Entrenamiento final y resumen de proporciones por cluster.

4.6. Interpretación de los Clusters

4.6.1. #0 – Perfil de Violencia contra las Personas

Este grupo se caracteriza por presentar la mayor participación relativa de delitos relacionados con **la vida y la integridad corporal (18.74 %)**, así como el valor más elevado en **libertad y seguridad sexual (3.86 %)**. En comparación con los demás grupos, la incidencia asociada a conductas violentas tiene un peso relativo mayor dentro de la composición delictiva total. Entre las entidades pertenecientes a este grupo se encuentran Campeche, Chiapas, Guerrero, Michoacán, Estado de México y Oaxaca.

4.6.2. #1 – Perfil Diversificado de Otros Bienes Jurídicos

La característica más distintiva de este grupo es la elevada participación de la categoría **Otros bienes jurídicos afectados (33.29 %)**, valor considerablemente superior al observado en los demás clústeres. Esto

indica una distribución delictiva menos concentrada en categorías tradicionales como patrimonio o familia y una mayor presencia relativa de delitos clasificados en rubros complementarios del conjunto de datos. Este perfil está conformado por Coahuila, Guanajuato, Tabasco y Yucatán.

4.6.3. #2 – Perfil Familiar y de Libertad Personal

Este clúster presenta la mayor proporción de delitos contra **la familia (19.93 %)** y contra **la libertad personal (1.93 %)**, superando al resto de los grupos en ambas categorías. El resultado sugiere una mayor concentración relativa de problemáticas asociadas al entorno familiar y a conductas que afectan la libertad individual. Las entidades agrupadas bajo este perfil son Chihuahua, Durango, Hidalgo, Nayarit, Nuevo León, Quintana Roo, San Luis Potosí, Sinaloa, Sonora, Tamaulipas, Veracruz y Zacatecas.

4.6.4. #3 – Perfil Patrimonial

Este grupo concentra la mayor participación de delitos contra **el patrimonio (55.04 %)**, representando más de la mitad de la incidencia promedio del clúster. La composición observada refleja una predominancia de delitos patrimoniales, como robos, fraudes y conductas relacionadas con afectaciones económicas. Entre las entidades pertenecientes a este perfil se encuentran Aguascalientes, Baja California, Baja California Sur, Ciudad de México, Colima, Jalisco, Morelos, Puebla, Querétaro y Tlaxcala.

4.7. Tabla de Segmentación

Tabla 1: Segmentación de entidades por clúster y perfil identificado

Clúster	Perfil Identificado	Entidades Federativas Coincidentes
0	Perfil de Violencia contra las Personas	Campeche, Chiapas, Guerrero, Michoacán, Estado de México, Oaxaca
1	Perfil Diversificado / Otros Bienes Jurídicos	Coahuila, Guanajuato, Tabasco, Yucatán
2	Perfil Familiar y Libertad Personal	Chihuahua, Durango, Hidalgo, Nayarit, Nuevo León, Quintana Roo, San Luis Potosí, Sinaloa, Sonora, Tamaulipas, Veracruz, Zacatecas
3	Perfil Patrimonial	Aguascalientes, Baja California, Baja California Sur, Ciudad de México, Colima, Jalisco, Morelos, Puebla, Querétaro, Tlaxcala

4.8. Proyección PCA

A nivel general, la proyección bidimensional permite apreciar que los cuatro grupos identificados por K-Means muestran patrones diferenciados dentro del espacio de características, proporcionando una representación visual coherente con la estructura de agrupamiento obtenida por el modelo.

```
1 #| label: clustering-final-visualization
2 #| fig-cap: "Visualización de la Segmentación de Entidades Federativas en 4 Perfiles
   Criminales (Proyección PCA 2D)"
3
```

```

4 # Construir la visualización del Scatter Plot
5 plt.figure(figsize=(8, 4), dpi=config.PLOT_DPI)
6
7 sns.scatterplot(
8     data=df_clusters,
9     x="pca_1",
10    y="pca_2",
11    hue="cluster",
12    palette="tab10",
13    s=160,
14    style="cluster",
15    alpha=0.9
16 )
17
18 # Etiquetar cada punto con el nombre de su respectivo estado
19 for i in range(len(df_clusters)):
20     plt.text(
21         x=df_clusters["pca_1"][i] + 0.04,
22         y=df_clusters["pca_2"][i] + 0.04,
23         s=df_clusters["entidad"][i],
24         fontsize=8,
25         alpha=0.8
26     )
27
28 plt.title(f"Segmentación de Entidades Federativas en {N_CLUSTERS_OPTIMO} Perfiles Criminales
29           (Proyección PCA 2D)")
30 plt.xlabel("Componente Principal 1 (Varianza Visual)")
31 plt.ylabel("Componente Principal 2 (Varianza Visual)")
32
33 # Líneas de referencia en el origen
34 plt.axhline(0, color="grey", linestyle="--", alpha=0.3)
35 plt.axvline(0, color="grey", linestyle="--", alpha=0.3)
36
37 plt.tight_layout()
38 plt.show()

```

Listing 13: Visualización final de la segmentación en la proyección PCA 2D.

Para comprender la geometría de las entidades federativas en la proyección PCA, analizamos la matriz de cargas (loadings), la cual indica la contribución y correlación lineal de cada Bien Jurídico Afectado con las dos primeras componentes principales (ejes del plano).

```

1 #| label: clustering-pca-loadings
2 # Extraer la matriz de loadings (componentes_ x variables)
3 loadings = clustering_pipe.pca.components_
4

```



Figura 6: Visualización PCA 2D de la segmentación (marcador de posición)

```
5 # Construir un DataFrame elegante para analizar la composición
6 df_loadings = pd.DataFrame(
7     loadings.T, # Transponemos para que las variables queden en las filas
8     columns=["Componente Principal 1 (PC1)", "Componente Principal 2 (PC2)"],
9     index=clustering_pipe.features_names
10 )
11
12 df_loadings.round(3)
```

Listing 14: Extracción y presentación de loadings PCA.

Los coeficientes muestran que la Componente Principal 1 (PC1) está dominada por un contraste entre *El patrimonio* (carga positiva alta) y variables asociadas al entorno familiar y social, como *La familia* y *La libertad y la seguridad sexual* (cargas negativas). En consecuencia, las entidades ubicadas hacia la derecha del plano tienden a presentar una mayor proporción relativa de delitos patrimoniales, mientras que las ubicadas hacia la izquierda muestran una mayor participación relativa de las categorías familiares y sociales.

Tabla 2: Matriz de cargas (loadings) de las dos primeras componentes principales

Bien Jurídico Afectado	Componente Principal 1 (PC1)	Componente Principal 2 (PC2)
El patrimonio	0.567	-0.332
La familia	-0.564	0.030
La libertad y la seguridad sexual	-0.459	-0.137
La sociedad	-0.047	0.322
La vida y la integridad corporal	-0.095	-0.325
Libertad personal	-0.368	-0.450
Otros bienes jurídicos afectados	-0.058	0.677

Por su parte, la Componente Principal 2 (PC2) está fuertemente influenciada por *Otros bienes jurídicos afectados* (0.677). Esto explica por qué las entidades del Cluster 1 como Yucatán, Coahuila, Guanajuato y Tabasco, aparecen desplazadas hacia la parte superior de la gráfica, pues comparten una participación relativamente elevada de esa categoría respecto al resto del país.

La matriz de cargas también ayuda a interpretar el caso de Tlaxcala, que aparece aislado en la parte inferior derecha. Su ubicación sugiere una combinación de proporciones delictivas distinta a la observada en la mayoría de las entidades de su mismo clúster, aun cuando mantiene una fuerte orientación patrimonial.

La proximidad o aparente solapamiento de algunos puntos pertenecientes a distintos grupos dentro de la proyección bidimensional es un comportamiento esperado ya que la representación mediante PCA conserva únicamente el 55.32 % de la varianza total de los datos, dejando fuera aproximadamente el 44.68 % de la información contenida en las dimensiones restantes.

4.9. Perfiles bajo la Proyección PCA

4.9.1. #1 - Perfil Diversificado

Este grupo, conformado por Yucatán, Coahuila, Guanajuato y Tabasco, es el más claramente distinguible dentro de la proyección PCA, desplazándose hacia la región superior del plano. Esta separación visual resulta consistente con el análisis de los perfiles promedio, ya que corresponde al clúster con la mayor participación de la categoría **Otros bienes jurídicos afectados**, característica que lo diferencia del resto de las entidades federativas.

4.9.2. #0 y #2 - Perfiles de Violencia y Entorno Familiar

Ambos grupos ocupan principalmente la región central de la proyección y presentan algunos estados relativamente próximos entre sí. Esta situación sugiere que comparten ciertas características en las dos primeras componentes principales. No obstante, dicha cercanía la debemos interpretar con cuidado ya que la agrupación definitiva fue realizada en el espacio original de siete dimensiones, donde existen diferencias suficientes para que K-Means los clasifique en perfiles distintos.

4.9.3. #3 - Perfil Patrimonial

Este grupo exhibe un núcleo relativamente compacto en la región derecha del plano, donde se concentran entidades como Ciudad de México, Aguascalientes, Querétaro y Jalisco. La cohesión observada resulta consistente con su perfil predominantemente patrimonial, caracterizado por una elevada participación de delitos contra el patrimonio. Adicionalmente, destaca el caso de **Tlaxcala**, que aparece visualmente separado del núcleo principal del grupo. Aunque comparte la misma clasificación patrimonial, su ubicación sugiere una combinación de proporciones delictivas distinta a la observada en el resto de las entidades del clúster.

Podemos notar que algunos puntos pertenecientes a distintos grupos aparecen próximos entre sí dentro de la proyección bidimensional. Este comportamiento es esperado, ya que la representación mediante PCA conserva únicamente el 55.32 % de la varianza total de los datos, dejando fuera aproximadamente el 44.68 % de la información contenida en las dimensiones restantes.

5. Conclusiones